



ЕЛЕКТРОТЕХНИЧКИ ФАКУЛТЕТ
УНИВЕРЗИТЕТ У БЕОГРАДУ

ДИПЛОМСКИ РАД

**Испитивање границе учења
имитацијама у симулационом
окружењу за роботско извршавање
високо прецизних задатака**

Кандидат

Михајло Стевановић

Број индекса: 2022/0315

Ментор

Проф. др Коста Јовановић

јул 2026.

Предговор

Овај рад настао је у Лабораторији за роботiku Електротехничког факултета Универзитета у Београду, смештеној у Палати науке, као наставак студентске праксе коју је аутор претходно реализовао у истој лабораторији, под менторством проф. др Косте Јовановића.

Истраживање је спроведено у оквиру учешћа лабораторије на такмичењу Intrinsic AI for Industry Challenge, које организује компанија Intrinsic (Alphabet Inc.), а које је усмерено на задатке прецизне роботске манипулације у индустријском контексту. Рад је део ширег тимског пројекта посвећеног аутоматском уметању кабла у конекторски порт. У оквиру тог пројекта, развој скриптоване *oracle* политике и прикупљање скупа демонстрација реализовао је колега Добрица Јанковић; ова теза се, на тако прикупљеним демонстрацијама, фокусира на експерименталну студију метода учења имитацијама (*ACT* и *Diffusion Policy*).

Захвалница

Желим да изразим искрену захвалност проф. др Кости Јовановићу на указаном поверењу и прилици да своју студентску праксу, а потом и дипломски рад, реализујем у лабораторији Електротехничког факултета у Палати Науке. Рад у том окружењу пружио ми је непроцењиво практично искуство и непосредан увид у процес научноистраживачког рада.

Посебну захвалност дугујем својим менторима, Давиду Сеничићу и др Филипу Бечановићу, на издвојеном времену, стрпљењу и знању које су несебично делили са мном током рада на овом пројекту. Захваљујући њиховим упутствима, конкретним референцама и правовременим смерницама успео сам да попуним кључне празнине у знању и да рад доведем до краја.

Захваљујем се и свим сарадницима лабораторије за роботiku на колегијалном радном окружењу и свакодневној размени идеја.

Михајло Стевановић
У Београду, јул 2026. године

Садржај

Предговор	i
Захвалница	ii
Списак скраћеница	v
1 Увод	1
1.1 Циљеви рада и истраживачка питања	2
1.2 Допринос рада	2
1.3 Структура рада	2
2 Преглед литературе	3
2.1 Учење имитацијама и клонирање понашања	3
2.2 Груписање акција трансформерима (<i>ACT</i>)	3
2.3 Дифузиона политика (<i>DP</i>)	4
2.4 Роботска манипулација деформабилним линеарним објектима	5
2.5 Синтеза прегледа и позиционирање рада	6
3 Методологија	7
3.1 Формулација проблема	7
3.2 Имплементација <i>ACT</i> политике	9
3.3 Имплементација дифузионе политике	11
4 Експериментална постава	12
4.1 Симулационо окружење	12
4.2 Сензори, опсервације и акције	12
4.3 Скуп демонстрација	12
4.4 Хиперпараметри обуке	13
4.5 Рачунарски ресурси и трошак обуке	13
4.6 Протокол евалуације	14
4.7 План експеримената	15
5 Резултати	17
5.1 Криве учења	17
5.2 Зависност успешности од броја демонстрација (серија А)	18
5.3 Поређење <i>ACT</i> и <i>DP</i> (серија Б)	18
5.4 Анализа грешака и плато перформанси (серија В)	20
6 Дискусија	24
6.1 Тумачење резултата у односу на циљеве рада	24
6.2 Ограничења	25
7 Закључак	26
Списак слика	26
Списак табела	27

Списак скраћеница

ACT	<i>Action Chunking with Transformers</i> , трансформерска архитектура политике са груписањем акција
AIC	<i>AI for Industry Challenge</i> , такмичење у оквиру ког је рад реализован
BC	<i>Behavioral Cloning</i> , клонирање понашања
CE	<i>Cross-Entropy</i> , унакрсна ентропија (функција губитка)
CVAE	<i>Conditional Variational Autoencoder</i> , условни варијациони аутоенкодер
DDPM	<i>Denoising Diffusion Probabilistic Models</i> , вероватносни дифузиони модели са одшумљавањем
DiffIK	<i>Differential Inverse Kinematics</i> , диференцијална инверзна кинематика
DLO	<i>Deformable Linear Object</i> , деформабилни линеарни објекат
DP	<i>Diffusion Policy</i> , дифузиона политика
ECDF	<i>Empirical Cumulative Distribution Function</i> , емпиријска функција расподеле
FiLM	<i>Feature-wise Linear Modulation</i> , линеарна модулација обележја
GPU	<i>Graphics Processing Unit</i> , графичка процесорска јединица
IL	<i>Imitation Learning</i> , учење имитацијама
KL	<i>Kullback-Leibler</i> (дивергенција)
MSE	<i>Mean Squared Error</i> , средњеквадратна грешка
QR	<i>Quick Response</i> (код)
RGB	<i>Red-Green-Blue</i> , колор модел са три канала боје
SFP	<i>Small Form-factor Pluggable</i> , стандардни мрежни примопредајник и одговарајући порт
SR	<i>Success Rate</i> , стопа успешности
TCP	<i>Tool Center Point</i> , радна тачка алата робота
VRAM	<i>Video Random Access Memory</i> , меморија графичке картице

1 Увод

Савремена индустријска аутоматизација суочава се са растућом потребом за роботским системима способним да извршавају задатке прецизне монтаже (енгл. *assembly*) које је, до скоро, било могуће обавити искључиво уз помоћ руке оператора. Кабловска инфраструктура, коју чине конектори, кабловске везице и сродни савитљиви елементи, незаобилазна је у производним линијама аутомобилске, ваздухопловне и медицинске индустрије. Упркос дугогодишњем напретку у роботској манипулацији, аутоматско уметање (енгл. *insertion*) кабла у конекторски порт остаје нерешен проблем и директно ограничава степен аутоматизације у производним погонима.

Овај задатак представља парадигматски пример такозваног проблема деформабилних линеарних објеката (енгл. *deformable linear objects*, DLO). За разлику од крутих тела, кабл испољава комплексну механику деформације која се не може поуздано унапред предвидети: чак и при идентичним почетним условима, конфигурација кабла у простору варира на начин неподложен аналитичком моделовању. Истовремено, успешно уметање захтева прецизност на нивоу неколико милиметара, будући да свако одступање завршног механизма (енгл. *end-effector*) изнад те границе резултира неуспехом задатка. Ова комбинација непредвидивости деформације и захтеване прецизности чини аутоматско уметање кабла једним од отворених проблема индустријске роботике.

Овај рад настао је у оквиру учешћа на такмичењу Intrinsic AI for Industry Challenge, које организује компанија Intrinsic (Alphabet Inc.), а које је усмерено на задатке прецизне роботске манипулације у индустријском контексту. За потребе учесника, Intrinsic је обезбедио потпуно конфигурисано симулационо окружење. Оно обухвата платформу NVIDIA Isaac Sim за физичку симулацију и фотореалистично приказивање сцене засновано на графичким процесорима (енгл. *GPU*), уз праћење зрака (енгл. *ray tracing*); OpenUSD склопове за дефиницију сцене, робота и задатка; те Docker контејнер са свим потребним библиотекама унапред инсталираним и међусобно усклађеним, из ког је могуће директно покретати симулације и тренирати политике. Оваква стандардизована поставка елиминисала је проблем конфигурације окружења и обезбедила потпуно репродуцибилне услове за систематско поређење метода.

Класични приступи решавању проблема DLO манипулације заснивају се на експлицитном моделовању геометрије и динамике кабла те планирању путање на основу тог модела. Ови приступи носе високу рачунарску цену и остају осетљиви на грешке услед немоделованог понашања. Као алтернатива, у овом раду истражују се методе *учења имитацијама* (енгл. *imitation learning*, IL), парадигма у којој агент политику (пресликовање опсервација у акције) учи директно из демонстрација стручног агента, без потребе за експлицитним моделом динамике окружења. Конкретно, поређене су две савремене IL архитектуре: *Action Chunking with Transformers (ACT)* [1] и *Diffusion Policy (DP)* [2], обе у формулацији клонирања понашања (енгл. *behavioral cloning*, BC). Скуп демонстрација прикупљен је путем такозване *oracle* политике, скриптованог агента заснованог на машини стања (енгл. *state machine*) коме је, за разлику од тренираних политика, омогућен привилегован приступ апсолутним координатама циљног порта у симулационом окружењу. Ова политика развијена је у оквиру ширег истраживачког пројекта и у овом раду представља фиксну, унапред дату компоненту тока података; њена интерна имплементација стога није предмет ове студије, већ се користи као стандардизован извор демонстрација. Тренирани модели ту информацију не поседују, већ уче искључиво из опсервација (RGB слике камере, позиција завршног механизма) и акција које је *oracle* политика извршила, чиме је задатак учења реалистично отежан у складу са

ограничењима стварних роботских система.

1.1 Циљеви рада и истраживачка питања

Централно истраживачко питање рада гласи: *колико далеко, и под којим условима, методе учења имитацијама могу да достигну задовољавајући ниво перформанси на задатку с милиметарском прецизношћу?* Из овог општег питања изведени су следећи циљеви рада:

- Ц1. Одредити оквирни минималан број демонстрација потребан да модел достигне прихватљиву стопу успешности (енгл. *success rate*).
- Ц2. Упоредити скалабилност архитектура *ACT* и *Diffusion Policy* у односу на величину скупа података за обуку.
- Ц3. Идентификовати плато перформанси ових метода на задатку овог типа, односно ниво на коме се перформансе заустављају упркос даљем повећању обима података, и детерминисати факторе који га одређују.

Првобитним планом рада био је предвиђен и додатни правац, испитивање утицаја аугментације података и синтетичког шума на робустност политике, али он није реализован у оквиру ове студије. Будући да су обе архитектуре, на сва три нивоа величине скупа, показале веома ниску стопу успешности (реда 1 %) са изразитим и архитектурно независним платоом заустављања (одељак 5), варирање аугментације и шума не би променило основни налаз; тај правац је стога наведен као правац будућег рада (одељак 7).

1.2 Допринос рада

Допринос овог рада је троструки. Прво, пружа се систематска експериментална студија граница двеју савремених ИЛ метода на задатку високе прецизности, у контролисаном симулационом окружењу и над демонстрацијама прикупљеним заједничком *oracle* политиком. Друго, анализира се зависност перформанси од величине скупа података и директно се пореди скалабилност архитектура *ACT* и *Diffusion Policy* при усклађеним условима обуке и евалуације. Треће, кроз расподелу минималне удаљености $d_{\min}$ и бочног одступања од осе уметања карактерише се плато перформанси ових метода на задатку милиметарске прецизности и идентификују чиниоци који га одређују.

1.3 Структура рада

Рад је организован на следећи начин. Поглавље 2 даје преглед релевантне литературе из области учења имитацијама, са посебним освртом на *ACT* и *Diffusion Policy*, као и сродне радове о роботској манипулацији деформабилним објектима. У Поглављу 3 описују се формулација проблема, архитектуре модела и ток података, укључујући заједничку *oracle* политику као контекст у коме настаје скуп демонстрација. Поглавље 4 детаљно излаже симулационо окружење, простор опсервација и акција, хиперпараметре и метрике евалуације. Резултати свих експерименталних димензија приказани су у Поглављу 5, а њихова интерпретација и ограничења дискутовани у Поглављу 6. Поглавље 7 доноси закључна разматрања и правце будућих истраживања.

2 Преглед литературе

2.1 Учење имитацијама и клонирање понашања

Учење имитацијама (IL) је парадигма у оквиру које агент стиче политику π опонашањем стручног демонстратора, без директног дефинисања функције награде окружења. Најједноставнији облик IL-а је клонирање понашања (BC), уведено у контексту аутономне навигације у систему ALVINN [3]. У BC формулацији, политика се тренира надгледаним учењем на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$:

$$\pi^* = \arg \min_{\pi} \mathbb{E}_{(\mathbf{o}, \mathbf{a}) \sim \mathcal{D}} [\mathcal{L}(\pi(\mathbf{o}), \mathbf{a})], \quad (1)$$

где $\mathbf{o}$ означава опсервацију, $\mathbf{a}$ акцију стручног агента, а $\mathcal{L}$ критеријумску функцију губитка.

Кључно ограничење BC-а је проблем акумулације грешке: мала одступања у предвиђеним акцијама нагомиланим ефектом одводе агента у стања која нису покривена скупом демонстрација, а политика нема усвојеног понашања за реоријентацију и поправку из таквих стања. Овај феномен, познат као помак расподеле (енгл. *distribution shift*), математички је формализовао Ross et al. [4], а у истом раду предложен је алгоритам *Dagger* (Dataset Aggregation), који скуп демонстрација итеративно обогаћује стањима насталим током евалуације (енгл. *rollout*) тренираног агента. Свеобухватна студија Mandlekar et al. [5] на скупу референтних задатака *Robomimic* (енгл. *benchmark*) показала је да на успешност BC-а у роботској манипулацији пресудно утичу квалитет и покривеност простора стања у демонстрацијама, а не искључиво архитектура модела. У истом духу, Belkhale et al. [6] показују да обим и квалитет скупа демонстрација често одређују горњу границу перформанси више него сам избор алгоритма, што непосредно мотивише питање колико је демонстрација заиста потребно за прихватљиву стопу успешности (циљ Ц1).


2.2 Груписање акција трансформерима (ACT)

ACT је метода учења имитацијама коју су предложили Zhao et al. [1] за задатке прецизне биманипулације. Централни допринос је концепт груписања акција (енгл. *action chunking*): уместо предвиђања јединичне акције у сваком временском кораку, политика предвиђа блок (енгл. *chunk*) од k узастопних акција $(\mathbf{a}_t, \mathbf{a}_{t+1}, \dots, \mathbf{a}_{t+k-1})$. Ефективни хоризонт задатка тако се смањује за фактор k , чиме се директно ублажава проблем акумулације грешке [4], будући да политика уместо T независних одлука доноси свега $\lceil T/k \rceil$.

Архитектура ACT-а комбинује условни варијациони аутоенкодер (CVAE) и кодер-декодер трансформер [7] (Сл. 1):

- **Кодер CVAE-а** (активан искључиво током тренинга): прима секвенцу акција из демонстрације и тренутне позиције зглобова, те их сажима у латентну променљиву $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$. Улога CVAE-а је моделовање вишемодалности у демонстрацијама, при чему се различити стилови извршавања истог задатка кодирају у различите вредности $\mathbf{z}$. У фази примене, кодер CVAE-а се изоставља, а вредност латентног вектора $\mathbf{z}$ поставља на нулу.

- **Трансформерски декодер:** прима визуелне одлике N RGB камера, издвојене визуелном кичмом (енгл. *backbone*), тј. основном мрежом за издвајање одлика, овде *ResNet-18* [8], као и позиције зглобова и $\mathbf{z}$, те механизмом унакрсне пажње (енгл. *cross-attention*), којим се предвиђене акције повезују са релевантним визуелним одликама, генерише предвиђени блок акција. Дизајн декодера заснован је на *DETR* [9] архитектури са учивим позиционим кодовима у улози упитних вектора.



Слика 1: Архитектура *ACT* политике: кодер *CVAE*-а (лево) сажима секвенцу акција и позиције зглобова у латентну променљиву $\mathbf{z}$, док трансформерски кодер-декодер (десно) на основу слика камера, позиција зглобова и $\mathbf{z}$ предвиђа секвенцу акција. Преузето из [1].

Критеријумска функција током тренинга комбинује L1 реконструкцијску грешку и KL регуларизацију:

$$\mathcal{L}_{\text{ACT}} = \mathbb{E}[\|\hat{\mathbf{a}} - \mathbf{a}\|_1] + \beta \cdot D_{\text{KL}}(\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2 \mathbf{I}) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})), \quad (2)$$

где је β хиперпараметар (подразумевано $\beta = 10$) који уравнотежује прецизност предвиђања и регуларизацију латентног простора.

За глаткост покрета при преклапајућим акцијским блоковима, *ACT* опционо примењује временско усредњавање (енгл. *temporal ensembling*): предвиђања за исти тренутак из вишеструких узастопних читавања политике комбинују се са експоненцијалним тежинама $w_i = e^{-m \cdot i}$. На задацима прецизне биманипулације у физичком окружењу *ACT* постиже стопу успешности од 80–96% [1], уз значајно надмашивање референтних метода BC-ConvMLP, BeT и VINN. Аблациона студија у истом раду показала је да само повећање величине блока са $k=1$ на $k=100$ побољшава стопу успешности са 1% на 44% на репрезентативном задатку биманипулације.

2.3 Дифузиона политика (DP)

Diffusion Policy (DP) је метода учења политике коју су увели Chi et al. [2], заснована на одшумљавању дифузијским вероватносним моделима (*DDPM*) [10] примењеним на простор акција роботске политике. Кључна идеја је представљање условне расподеле акција $p(\mathbf{A}_t \mid \mathbf{O}_t)$ кроз итеративни поступак уклањања шума:


$$\mathbf{x}^{(k-1)} = \alpha(\mathbf{x}^{(k)} - \gamma \epsilon_{\theta}(\mathbf{x}^{(k)}, k, \mathbf{O}_t)) + \boldsymbol{\eta}, \quad \boldsymbol{\eta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}), \quad (3)$$

где $\mathbf{x}^{(K)}$ представља иницијални Гаусов шум, а ϵ_{θ} мрежу тренирану да предвиди шум условљен опсервацијом $\mathbf{O}_t$. Поступак поступно претвара насумичан шум у кохерентан

акцијски план кроз K корака одшумљавања. Применом *DDIM* [11] шеме потребан број ових корака смањује се са 100 на свега 10, чиме се постиже кашњење испод 0,1 s при примени политике на GPU.

DP такође предвиђа секвенце акција (T_p корака), али извршава само $T_a < T_p$ пре следеће активације политике, остварујући баланс дугорочног планирања и брзе реакције на тренутне опсервације. Слика 2 приказује општу формулацију методе и две предложене архитектуралне варијанте:

- **Conv-DP**: 1D временске конволуције, при чему се условљавање опсервацијом остварује *FiLM* модулацијом (енгл. *Feature-wise Linear Modulation*) [12]. *FiLM* сваку одлику мреже, зависно од услова, множи наученим фактором и додаје јој научени померај (афина трансформација облика $ax + b$, примењена по каналу). Ова варијанта поуздана је у широком спектру задатака.
- **Trans-DP**: трансформерски декодерски блокови са каузалним маскирањем пажње; надмашује *Conv-DP* на задацима са нагло променљивим и вишемодалним акцијама.



Слика 2: Архитектура *Diffusion Policy*. **Лево** је општа формулација: политика $\epsilon_{\theta}(\mathbf{O}, \mathbf{A}, k)$ узима последњих T_o корака опсервације $\mathbf{O}_t$ и итеративним одшумљавањем зашумљене секвенце ($\mathbf{A}_t^K \rightarrow \mathbf{A}_t^0$, кроз K корака) генерише акције дуж хоризонта предвиђања T_p , од којих се извршава првих T_a . **У средини** је конволуциона варијанта (*Conv-DP*): опсервација $\mathbf{O}_t$ *FiLM* модулацијом ($a \cdot \mathbf{x} + b$) условљава Conv1D слојеве мреже за одшумљавање. **Десно** је трансформерска варијанта (*Trans-DP*): векторска репрезентација (енгл. *embedding*) опсервације улази у унакрсну пажњу сваког декодерског блока уз каузално маскирање пажње. Преузето из [2].

Евалуација на 15 задатака из четири скупа референтних задатака (укључујући *Robotomimic* [5]) показала је просечно унапређење од 46,9% у односу на претходне BC методе [2]. Кључна предност *DP*-а у односу на детерминистичке регресионе политике је природна способност моделовања вишемодалних расподела акција: у ситуацијама са вишеструким оптималним путањама *DP* не пати од колапса мода (енгл. *mode collapse*).

2.4 Роботска манипулација деформабилним линеарним објектима

Деформабилни линеарни објекти (DLO), попут жица, каблова и сличних савитљивих елемената, представљају засебну и отворену класу проблема у роботској манипулацији [13]. За разлику од крутих тела, чији је положај у потпуности одређен шест степени слободе, стање DLO-а захтева опис бесконачно-димензионог конфигурационог

простора деформације. Аналитичко моделовање ове динамике носи висок рачунарски захтев и оставља значајне немоделоване ефекте услед трења, вискоеластичности материјала и контакта са окружењем [13].

Традиционални приступи манипулацији DLO-а ослањали су се на сензоре силе и момента или на физичке моделе засноване на Косератовој (енгл. *Cosserat*) теорији еластичних штапова [14], постижући ограничену применљивост у условима непредвидивих деформација. Истраживања роботског уметања углавном су се бавила уметањем крутих делова у круте отворе (енгл. *peg-in-hole*); тако InsertionNet [15] комбиновањем визуелних и силомерних улаза постиже робусно уметање конектора преко више задатака, али уз претпоставку круте геометрије уметка. Задатак уметања кабла у конекторски порт додатно захтева прецизност на нивоу неколико милиметара, будући да свако одступање завршног механизма изнад тог прага резултира механичким неуспехом, при чему сам кабл, за разлику од крутог уметка, мења облик током контакта. Ова комбинација непредвидивости деформације и захтеване прецизности чини уметање кабла репрезентативним примером задатка за који методе које политику уче директно из демонстрација, попут *ACT* и *Diffusion Policy*, представљају природну алтернативу приступима заснованим на експлицитном моделу динамике.

2.5 Синтеза прегледа и позиционирање рада

Изложени преглед указује на три налаза који усмеравају остатак рада. Прво, у оквиру клонирања понашања горњу границу перформанси често одређују обим и покривеност скупа демонстрација пре него сам избор архитектуре [5, 6], због чега је питање потребног броја демонстрација (Ц1) методолошки првенствено. Друго, *ACT* [1] и *Diffusion Policy* [2] издвајају се као две водеће, али концепцијски различите ВС архитектуре: *ACT* хоризонт задатка скраћује груписањем акција, док *DP* вишемодалност расподеле акција моделује итеративним одшумљавањем; оба су, међутим, валидирана претежно на стандардним референтним скуповима задатака (нпр. *Robomimic*), а не на уметању с милиметарском толеранцијом. Треће, манипулација деформабилним линеарним објектима остаје отворен проблем у ком учење директно из демонстрација (без експлицитног модела динамике) представља природну алтернативу, али у ком захтевана прецизност и променљива геометрија кабла и даље нису систематски испитане.

Из ова три налаза произлази празнина коју рад попуњава: у литератури изостаје директно, контролисано поређење *ACT* и *Diffusion Policy* на задатку уметања деформабилног кабла високе прецизности, као и анализа њихове зависности од величине скупа демонстрација и отпорности на аугментацију и шум. Управо ту празнину адресирају циљеви рада: поређење скабилности двеју архитектура (Ц2) и одређивање потребног обима демонстрација (Ц1) ослањају се на налазе о пресудној улози података, а анализа платоа перформанси (Ц3) на специфичности уметања DLO изложене у одељку 2.4; испитивање утицаја аугментације и шума на осетљивост ВС-а на *distribution shift* [4] првобитно је планирано, али је, из разлога изложених у одељку 1.1, препуштено будућем раду. Методологија представљена у наредном поглављу операционализује ове циљеве кроз заједнички ток података и јединствен протокол евалуације обеју политика.

3 Методологија

Методолошки оквир рада обухвата четири целине: прикупљање демонстрација заједничком *oracle* политиком, формирање скупа демонстрација у *LeRobot* формату, тренинг политика клонирањем понашања и евалуацију у симулационом окружењу. Прве две целине, *oracle* политика и формирање скупа, развијене су у оквиру ширег пројекта и овде се приказују само на нивоу тока података, ради потпуности; тежиште овог рада су трећа и четврта целина, односно обука и систематска евалуација ИЛ политика. Кључна одлика поставе је асиметрија информација: *oracle* политика има приступ апсолутним координатама порта, док трениране политике одлучују искључиво на основу опсервација. Целокупан ток података приказан је на слици 3.

3.1 Формулација проблема

Задатак разматран у овом раду је аутономно уметање кабла у конекторски порт у симулационом окружењу са шестоосним роботом UR5e. Политика управља роботом на фреквенцији од 30 Hz и у сваком дискретном тренутку t прима опсервацију $\mathbf{o}_t$ и одређује акцију $\mathbf{a}_t$.

Простор опсервација. Опсервација у тренутку t састоји се од визуелне и проприоцептивне компоненте:

$$\mathbf{o}_t = (\mathbf{I}_t^c, \mathbf{I}_t^l, \mathbf{I}_t^r, \mathbf{s}_t), \quad (4)$$


где $\mathbf{I}_t^c, \mathbf{I}_t^l, \mathbf{I}_t^r \in \mathbb{R}^{H \times W \times 3}$ означавају RGB слике централне, леве и десне камере, а $\mathbf{s}_t \in \mathbb{R}^{56}$ проприоцептивни вектор стања добијен надовезивањем следећих величина (све изражене у базном координатном систему робота):

- $\mathbf{q}_t, \dot{\mathbf{q}}_t, \boldsymbol{\tau}_t \in \mathbb{R}^6$: позиције, брзине и моменти шест зглобова роботске руке,
- $\mathbf{p}_t^{\text{tcp}} \in \mathbb{R}^3, \mathbf{r}_t^{\text{tcp}} \in \mathbb{R}^4$: позиција и оријентација (кватернион) радне тачке алата (TCP),
- $\mathbf{p}_t^{\text{eef}} \in \mathbb{R}^3, \mathbf{r}_t^{\text{eef}} \in \mathbb{R}^4$: позиција и оријентација референтног оквира хватача,
- $\mathbf{v}_t^{\text{tcp}}, \boldsymbol{\omega}_t^{\text{tcp}}, \mathbf{v}_t^{\text{eef}}, \boldsymbol{\omega}_t^{\text{eef}} \in \mathbb{R}^3$: линеарне и угаоне брзине TCP-а и хватача,
- $\mathbf{w}_t \in \mathbb{R}^6$: сила и момент на завршном зглобу хватача (енгл. *wrist wrench*),
- $\mathbf{a}_{t-1} \in \mathbb{R}^6$: акција примењена у претходном временском кораку.

Кључно ограничење реалистичности задатка: политика не прима апсолутне координате циљног порта. Та информација је доступна искључиво *oracle* политици коришћеној за генерисање скупа демонстрација $\mathcal{D}$.

Простор акција. Акција политике у сваком временском кораку је прираштај позе TCP-а у картезијанском простору, изражен као шестодимензиони вектор:

$$\mathbf{a}_t = (\Delta \mathbf{p}_t, \Delta \boldsymbol{\theta}_t) \in \mathbb{R}^6, \quad (5)$$



Слика 3: Ток података кроз систем: *oracle* политика са приступом координатама порта генерише демонстрације преко машине стања и DiffIK контролера, успешне епизоде се чувају у *LeRobot* скуп демонстрација, на коме се тренирају *ACT* и *Diffusion Policy* политике, а потом евалуирају без привилеговане информације.

где $\Delta \mathbf{p}_t \in \mathbb{R}^3$ означава транслаторни прираштај, а $\Delta \boldsymbol{\theta}_t \in \mathbb{R}^3$ ротациони прираштај у форми вектора ротације (оса–угао). Излаз политике у опсегу $[-1, 1]$ скалира се пре прослеђивања контролеру, чиме се транслаторни прираштај по кораку ограничава на 1,5 cm, а ротациони на 0,025 rad по оси. Овако скалирани прираштај прослеђује се контролеру заснованом на диференцијалној инверзној кинематици (DiffIK), који методом пригушених најмањих квадрата (енгл. *damped least squares*, DLS) рачуна одговарајуће циљне позиције зглобова робота. Хватач је током целог задатка у затвореном положају, па акција не обухвата управљачку променљиву прстију хватача.

Формулација клонирања понашања. Задатак учења формулише се у оквиру клонирања понашања (1): политика π_θ тренира се на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$ генерисаних *oracle* политиком, надгледаном минимизацијом грешке предвиђене акције. Обе архитектуралне варијанте разматране у овом раду, *ACT* и *Diffusion Policy*, трениране су у идентичном BC оквиру на заједничком скупу демонстрација, чиме је обезбеђена поредивост резултата.

Метрике евалуације. Успешност политике мери се двама метрикама. Примарна је бинарна стопа успешности:

$$\text{SR} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\text{епизода } i \text{ успешна}], \quad (6)$$

где N означава укупан број евалуационих епизода. Епизода се сматра успешном ако врх за уметање достигне циљну позу, уз позициону грешку не већу од 3 mm и угаону грешку не већу од 4°, и ту позу задржи најмање 0,5 s, чиме се елиминишу пролазни додир без стварног уметања. Секундарна метрика је минимална еуклидска удаљеност врха за уметање од циљне позиције током епизоде:

$$d_{\min} = \min_{t \in [1, T]} \|\mathbf{p}_t^{\text{tip}} - \mathbf{p}^*\|_2, \quad (7)$$

где $\mathbf{p}_t^{\text{tip}} \in \mathbb{R}^3$ означава позицију врха за уметање у тренутку t , а $\mathbf{p}^* \in \mathbb{R}^3$ циљну позицију уметања. Метрика $d_{\min}$ омогућава квантификацију прецизности грешке и у неуспелим епизодама, пружајући финији увид у ниво перформанси изван бинарног критеријума (6).

3.2 Имплементација *ACT* политике

Архитектура *ACT*-а, описана у одељку 2.2, у овом раду инстанцирана је коришћењем имплементације из библиотеке *LeRobot*. Политика прима опсервацију $\mathbf{o}_t$ из (4) и предвиђа блок од k узастопних акција у простору (5), што је приказано на слици 4.


Визуелни део опсервације, односно слике три камере, кодира се *ResNet-18* backbone-ом, чији излаз чини скуп просторних токена за трансформерски декодер. Про-приоцептивни вектор $\mathbf{s}_t$ пројектује се линеарним слојем у засебан улазни токен. Кодер *CVAE*-а активан је искључиво током тренинга и моделује вишемодалност демонстрација кроз латентну променљиву $\mathbf{z}$, док се у фази примене поставља $\mathbf{z} = \mathbf{0}$. Тренинг се води минимизацијом комбиноване функције губитка (2).

Као имплементациони детаљ, уз главни излаз политике задржана је и помоћна глава за класификацију фазе задатка: линеарни слој над усредњеном репрезентацијом кодера

предвиђа тренутну фазу извршавања (ПРИЛАЗАК, ПОРАВНАЊЕ или УМЕТАЊЕ). Она се тренира унакрсном ентропијом као помоћним губитком мале тежине (0,1) и не утиче на излаз политике у фази примене.

Мотивација за ову помоћну главу лежи у структури задатка: уметање се природно разлаже на машину стања фаза ПРИЛАЗАК $\rightarrow$ ПОРАВНАЊЕ $\rightarrow$ УМЕТАЊЕ, а *oracle* политика генерише демонстрације управо у тој структури, па су ознаке фаза доступне из скупа демонстрација без додатног трошка. Док главни губитак клонирања понашања пружа релативно слаб надзор над визуелним кодером, класификација фазе уводи гушћи и семантички јаснији сигнал који кодер усмерава ка одликама релевантним за задатак (близина порту, степен поравнања, контакт), управо оним одликама које су потребне и главном задатку предвиђања акције. Тиме се очекује боље структурирана репрезентација и блага регуларизација против учења пречица, при чему се, пошто се глава у фази примене одбацује, сав ефекат остварује посредно, кроз научене одлике кодера. Пошто је тежина помоћног члана намерно мала (0,1), он усмерава репрезентацију без преузимања оптимизације од главног циља; његов изоловани допринос могуће је квантификовати аблацијом (обука са и без помоћне главе под иначе истоветним условима).

Ради повећања робусности на варијације осветљења и положаја камере, на улазне слике се током тренинга примењују фотометријске и геометријске аугментације. У фази примене политика користи временско усредњавање, чиме се преклапајућа предвиђања акцијских блокова комбинују у глатку управљачку секвенцу. Конкретне вредности хиперпараметара (величина блока k , тежина β , стопа учења и параметри аугментације) наведене су у одељку 4.




Слика 4: Улазно-излазна шема *ACT* политике примењене у овом раду: слике три камере (*ResNet-18*) и проприоцептивни вектор s_t (линеарни слој), уз латентну променљиву z , улазе у трансформерски кодер-декодер који предвиђа блок од k акција. Испрекидано је приказана помоћна глава за класификацију фазе, активна само у обуци (губитак 0,1-СЕ), чији циљеви (ПРИЛАЗАК/ПОРАВНАЊЕ/УМЕТАЊЕ) потичу из машине стања *oracle* политике. У фази примене $z = \mathbf{0}$ и примењује се временско усредњавање.

3.3 Имплементација дифузионе политике

Diffusion Policy инстанцирана је такође у оквиру библиотеке *LeRobot*, на истом скупу демонстрација $\mathcal{D}$ и са идентичним простором опсервација (4) и акција (5) као *ACT* (Сл. 5), чиме је обезбеђена поредивост двеју метода.

Коришћена је конволуциона варијанта (*Conv-DP*): мрежа за одшумљавање заснована је на једнодимензионом *U-Net*-у [16], а условљавање опсервацијом остварено је *FiLM* модулацијом. Сlike три камере кодирају се *ResNet-18* backbone-ом, а добијени визуелни дескриптори се заједно са проприоцептивним вектором $\mathbf{s}_t$ сажимају у условни вектор опсервације $\mathbf{O}_t$. Мрежа ϵ_θ тренира се да предвиди шум додат на акцијску секвенцу, у складу са (3), минимизацијом средње квадратне грешке предвиђеног шума. Као и код *ACT* политике, помоћна глава за класификацију фазе задатка задржана је и у овој политици, са идентичном тежином помоћног губитка (0,1) над условним вектором опсервације, ради конзистентности поставке двеју метода. Детаљан ток података кроз мрежу (од кодирања опсервације, преко *FiLM*-условљеног *U-Net*-а, до итеративног одшумљавања и рецедирајућег извршавања) приказан је на слици 5.

У фази примене, акцијска секвенца се генерише итеративним одшумљавањем из Гаусовог шума, условљеним текућом опсервацијом, при чему се користи *DDPM* шема са 100 корака одшумљавања. Политика предвиђа секвенцу од T_p корака, а извршава њених првих $T_a < T_p$ пре поновне активације (рецедирајући хоризонт). Вредности хиперпараметара (хоризонти T_p и T_a , број корака одшумљавања, стопа учења) дате су у одељку 4.



Слика 5: Детаљна архитектура и ток података *Diffusion Policy* примењене у овом раду. Сlike три камере и проприоцептивно стање (за $n_{\text{obs}} = 2$ корака) кодирају се дељеним *ResNet-18* backbone-ом са просторним softmax-ом (32 тачке) у условни вектор $\mathbf{O}_t$. Мрежа за одшумљавање (1D *U-Net* ϵ_θ) условљена је *FiLM* модулацијом из $\mathbf{O}_t$ и синусоидном векторском репрезентацијом корака дифузије t , и предвиђа шум $\hat{\epsilon}$ додат на зашумљену акцијску секвенцу $\mathbf{a}_t$. У обуци се минимизује средња квадратна грешка предвиђеног шума уз помоћни губитак фазе; у примени се поступак понавља 100 пута (*DDPM*) да би се из чистог шума генерисала секвенца од $T_p = 16$ акција, од којих се извршава првих $T_a = 8$ (рецедирајући хоризонт).

4 Експериментална постава

Ово поглавље описује симулационо окружење, конфигурацију сензора и контролера, хиперпараметре обуке обеју политика и протокол евалуације. Циљ је да постава буде описана довољно детаљно да омогући репродукцију резултата.

4.1 Симулационо окружење

Сви експерименти изведени су у симулатору Isaac Lab, надградњи платформе NVIDIA Isaac Sim, у оквиру задатка регистрованог под идентификатором AIC-Port-Insertion-v0. Задатак је реализован као окружење засновано на менаџерима (енгл. *manager-based*), где су сцена, опсервације, акције, догађаји и услови завршетка епизоде дефинисани засебним конфигурационим модулима.

Робот је шестоосни UR5e, монтиран са ротацијом од 180° око вертикалне осе радне површине; услед тога се проприоцептивне величине изражавају у координатном систему базе робота (енгл. *root frame*), који одговара ономе што робот „види” путем директне кинематике. Физичка симулација извршава се кораком $\Delta t_{\text{sim}} = 1/120 \text{ s}$, док се управљачка петља покреће на сваки четврти физички корак (фактор редукције 4), што даје ефективну фреквенцију политике од 30 Hz. Максимално трајање епизоде износи 120 s, односно до 3600 управљачких корака. Сцена је осветљена куполним светлом чији се интензитет и положај насумично варирају између епизода (енгл. *domain randomization*), ради робусности на услове осветљења.

4.2 Сензори, опсервације и акције

Визуелну опсервацију чине три RGB камере (централна, лева и десна), реализоване као TiledCamera са пинхол моделом пројекције, резолуције 224×224 пиксела и жишне даљине 22,48 mm. Слике се прослеђују политици у изворном осмобитном формату (без нормализације на нивоу окружења). Проприоцептивни вектор $\mathbf{s}_t \in \mathbb{R}^{56}$ и простор акција $\mathbf{a}_t \in \mathbb{R}^6$ дефинисани су у одељку 3.1; излаз политике у опсегу $[-1, 1]$ скалира се на највише 1,5 cm translације и 0,025 rad ротације по управљачком кораку.

Поред опсервационе групе доступне политици, окружење дефинише и привилеговану групу (енгл. *cheatcode*) која садржи апсолутне координате улаза и лежишта порта те фракцију уметнутости. Ова група служи искључиво *oracle* политици при генерисању демонстрација и није доступна тренираним политикама током евалуације, чиме се остварује описана асиметрија информација.

4.3 Скуп демонстрација

Скуп демонстрација генерисан је *oracle* политиком из Поглавља 3 (слика 3), при чему се у скуп уписују искључиво успешне епизоде. Подаци су организовани у *LeRobot* формату (верзија v3.0): проприоцептивна стања, акције и ознаке фазе чувају се у *parquet* датотекама, а токови три камере као видео-записи. Основне карактеристике скупа, релевантне за репродукцију експеримената, сажете су у Табели 1.

Табела 1: Основне карактеристике скупа демонстрација.

Карактеристика	Вредност
Формат скупа	LeRobot v3.0
Број епизода (само успешне)	30 290
Укупан број кадрова	8 183 171
Фреквенција узорковања	30 Hz
Просечна дужина епизоде	≈ 270 кадрова (≈ 9 s)
Визуелне опсервације	3 RGB камере, 224×224 (кодек AV1)
Проприоцептивно стање	$\mathbf{s}_t \in \mathbb{R}^{56}$
Акција	$\mathbf{a}_t \in \mathbb{R}^6$
Анотација фазе	3 класе (ПРИЛАЗАК/ПОРАВНАЊЕ/УМЕТАЊЕ)
Величина на диску	≈ 47 GB

4.4 Хиперпараметри обуке

Обе политике трениране су у оквиру библиотеке *LeRobot*, на заједничком скупу демонстрација и са идентичним простором опсервација и акција. Хиперпараметри *ACT* политике дати су у Табели 2, а *Diffusion Policy* у Табели 3.

Табела 2: Хиперпараметри *ACT* политике. Број корака обуке усклађен је на ≈ 4 епохе за сваку величину скупа ($N_{\text{demo}} = 1\,000/10\,000/30\,290$).

Хиперпараметар	Вредност
Визуелни backbone	ResNet-18
Величина акцијског блока k	100
Тежина KL члана β	10
Димензија модела	512
Број глава пажње	8
Слојеви кодера / декодера	4 / 1
Темпорално усредњавање (примена)	да ($\alpha = 0,01$)
Тежина помоћног губитка фазе	0,1
Оптимизатор	AdamW
Стопа учења (глава / backbone)	$3 \cdot 10^{-5} / 1 \cdot 10^{-5}$
Величина серије (batch)	64
Број корака обуке (1k/10k/30k)	17k / 169k / 512k

4.5 Рачунарски ресурси и трошак обуке

Све обуке изведене су на једној радној станици са графичком картицом NVIDIA GeForce RTX 5090 (32 GB VRAM) и процесором AMD Ryzen 9 9950X, уз декодовање видео-демонстрација преко *torchcodec*-а (8–16 радних нити за учитавање података). Ради репродуцибилности резултата, сви експерименти извршени су у Docker контејнеру, а верзије кључног софтвера и библиотека коришћених у експериментима наведене су у Табели 4. Табела 5 сажима трошак обуке по конфигурацији. *Diffusion Policy* готово потпуно засити графичку картицу (просечна искоришћеност $\approx 97\%$), док *ACT*, услед

Табела 3: Хиперпараметри *Diffusion Policy*. Средњи и пун скуп (10 000/30 290) тренирани су $\approx 1,56$ епохе, док је пилот (1 000) обучен краће ($\approx 0,6$ епоха, batch 32).

Хиперпараметар	Вредност
Визуелни backbone	ResNet-18
Архитектура мреже за одшумљавање	1D U-Net
Условљавање опсервацијом	FiLM
Број опсервационих корака n_{obs}	2
Хоризонт предвиђања T_p	16
Хоризонт извршавања T_a	8
Исечак слике (random crop)	216×216
Распоред шума (енгл. <i>noise schedule</i>)	squaredcos_cap_v2
Циљ предвиђања	шум (ϵ)
Број корака дифузије (обука)	100
Распоред шума у примени	DDPM, 100 корака
Тежина помоћног губитка фазе	0,1
Оптимизатор	Adam ($\beta_1=0,95$, $\beta_2=0,999$)
Стопа учења	$1 \cdot 10^{-4}$ (косинусни распоред)
Опадање тежина	$1 \cdot 10^{-6}$
Величина серије (batch)	64 (32 за пилот)
Број корака обуке (1k/10k/30k)	5k / 66k / 200k

укључене фотометријске и геометријске аугментације слика која се извршава на процесору, наизменично засити и испразни картицу (просечна искоришћеност $\approx 66\%$); тај образац приказан је на слици 6. Врхунско заузеће VRAM-а износило је ≈ 26 од 32 GB.

Табела 4: Верзије кључног софтвера и библиотека коришћених у експериментима.


Софтвер / библиотека	Верзија
Isaac Sim	5.1.0
Isaac Lab	0.54.3
Python	3.11.13
PyTorch	2.7.0 (CUDA 12.8)
torchvision	0.22.0
torchcodec	0.4.0
LeRobot	0.4.4
diffusers	0.35.2
Gymnasium	1.2.1
NumPy	1.26.4
NVIDIA драјвер	580.159.03

4.6 Протокол евалуације

Сваки трениран модел евалуира се на $N = 50$ независних епизода са насумичним почетним условима, без приступа привилегованим координатама порта. Перформансе се изражавају стопом успешности (6) и минималном удаљеношћу врха за уметање од

Табела 5: Трошак обуке по конфигурацији (RTX 5090). Број корака усклађен је по броју епоха над скупом; проток је измерен као просечан број корака оптимизације у секунди.

Конфигурација	Кораци	Епохе	Трајање	Проток [step/s]
ACT 1 000	17k	≈ 4	0,8 h	6,2
ACT 10 000	169k	≈ 4	6,4 h	7,3
ACT 30 290	512k	≈ 4	19,6 h	7,3
DP 1 000	5k	$\approx 0,6$	0,4 h	3,8
DP 10 000	66k	$\approx 1,6$	2,8 h	6,5
DP 30 290	200k	$\approx 1,6$	8,0 h	6,9



Слика 6: Просечна искоришћеност графичке картице током обуке на пуном скупу. *Diffusion Policy* (без аугментације) држи картицу засићеном ($\approx 97\%$), док је *ACT* (са аугментацијом на процесору) ограничен пропусношћу декодовања и аугментације ($\approx 66\%$).

циља (7). Епизода се сматра успешном када врх за уметање задржи позициону грешку испод 3 mm и угаону грешку испод 4° најмање 0,5 s; епизода се означава неуспелом по истеку времена или када робот остане непокретан изван циља дуже од 3 s. Скуп демонстрација описан је у одељку 4.3 (Табела 1), а утицај његове величине на перформансе анализира се у Поглављу 5 поређењем подскупова од 1 000 и 10 000 епизода са пуним скупом од 30 290 епизода.

4.7 План експеримената

Експерименти су осмишљени тако да директно адресирају циљеве рада постављене у Уводу. Заједничка основа свих експеримената је иста: исто симулационо окружење, исти простор опсервација и акција, заједнички извор демонстрација и идентичан протокол евалуације из одељка 4.6. Варира се само мали скуп контролисаних чинилаца, чиме се изоловано мери ефекат сваког од њих.

Независне променљиве. Систематски се варирају следећи чиниоци:

- **Архитектура политике:** *ACT* или *Diffusion Policy*, под иначе идентичним условима;

- **Величина скупа демонстрација:** број епизода за обуку N_{demo} на три нивоа (1 000, 10 000 и 30 290), односно пилот, средњи и пун подскуп, при чему је буџет обуке усклађен по броју епоха над скупом (≈ 4 епохе за *ACT*, односно сразмерно за *Diffusion Policy*).

Контролисане (фиксне) променљиве. Симулационо окружење, конфигурација сензора, простор опсервација и акција, скуп хиперпараметара архитектуре (Табеле 2 и 3), као и протокол евалуације држе се непроменљивим током поређења, како би уочене разлике у перформансама биле приписиве искључиво независним променљивим.

Понављања и извештавање. Свака конфигурација евалуира се на $N = 50$ епизода са насумичним почетним стањем (случајан положај плоче, конектора и услова осветљења). Две пуне политике (*ACT* и *Diffusion Policy* на 30 290 демонстрација) додатно су евалуиране преко три независна *seed*-а евалуације (*seed* је вредност којом се иницијализује генератор псеудослучајних бројева; укупно $3 \times 50 = 150$ епизода), ради процене варијабилности стопе успешности и метрика прецизности услед насумичног узорковања сцене; пилот конфигурације (1 000 демонстрација) евалуиране су на једном *seed*-у. Понављање обуке преко више *seed*-ова изостављено је услед рачунских ограничења и наведено као методолошко ограничење у одељку 6. Пошто је стопа успешности веома ниска (реда 1 %), тежиште извештавања је на расподели минималне удаљености $d_{\min}$ и бочног одступања од осе, које пружају финију меру прецизности и типова грешке.

Серије експеримената и њихово мапирање на циљеве рада сажети су у Табели 6.

Табела 6: Серије експеримената и одговарајући циљеви рада.

Серија	Варирана променљива	Циљ рада
А	величина скупа демонстрација	Ц1, Ц2
Б	архитектура (<i>ACT</i> / <i>DP</i>)	Ц2
В	анализа грешака при најбољој конфигурацији	Ц3


Серија А утврђује зависност перформанси од броја демонстрација за обе архитектуре и тиме одговара на питање о потребном обиму података (Ц1) и о томе која метода боље скалира (Ц2). Серија Б продубљује директно поређење *ACT* и *DP* при једнаким условима. Коначно, серија В анализира природу преосталих неуспеха при најбољој постигнутој конфигурацији, кроз расподелу $d_{\min}$ и фазу задатка у којој долази до отказа, ради одређивања платоа перформанси и чинилаца који га детерминишу (Ц3).

5 Резултати


Резултати су организовани по серијама експеримената из одељка 4.7. Све вредности добијене су по протоколу евалуације из одељка 4.6. Стопа успешности извештава се као средња вредност преко K *seed*-ова уз стандардну девијацију, а прецизност преко расподеле минималне удаљености $d_{\min}$.

5.1 Криве учења

Слика 7 приказује кретање функције губитка обуке за обе архитектуре и све три величине скупа демонстрација (1 000, 10 000 и 30 290), на логаритамској скали. Код **Diffusion Policy** (слика 7а) укупни губитак сачињен је од дифузионог члана (предвиђање шума, средњеквадратна грешка) и помоћног члана унакрсне ентропије за класификацију фазе, са тежином 0,1; у свим конфигурацијама нагло опада током прве епохе и потом монотонно конвергира ка све нижем стационарном нивоу са порастом обима података: пилот (1 000) достиже $\approx 0,015$ након 5 000 корака (~ 22 min), средњи скуп (10 000) $\approx 0,007$ након 66 000 корака ($\sim 2,8$ h), а пун скуп (30 290) $\approx 0,006$ након $2 \cdot 10^5$ корака (12,8 милиона узорака, ~ 8 h); буџети средњег и пуног скупа усклађени су на $\approx 1,56$ епоха, док је пилот обучен краће ($\approx 0,6$ епоха). Код **ACT**-а (слика 7б), тренираног ≈ 4 епохе за сваку величину скупа (17 000, 169 000 и 512 000 корака), губитак (L_1 реконструкција акција уз помоћни губитак фазе) конвергира ка блиском платоу ($\approx 0,122 \rightarrow 0,114 \rightarrow 0,112$), уз тек благо снижење са обимом података; тај губитак није директно упоредив са дифузионим средњеквадратним губитком, па се две ординате пореде само по облику конвергенције, не по апсолутној вредности. Нижи стационарни губитак на већим скуповима очекивана је последица веће количине и разноврсности података. Будући да *LeRobot* подразумевано не издваја валидациони подскуп, праћен је искључиво губитак обуке; зато се конвергенција губитка не сме тумачити као доказ генерализације, што се додатно потврђује резултатима евалуације у наставку.



(a) *Diffusion Policy*



(б) *ACT*

Слика 7: Криве учења (лог–лог скала) за три величине скупа демонстрација. (а) Код *Diffusion Policy* финални губитак јасно опада са обимом података ($\approx 0,015 \rightarrow 0,007 \rightarrow 0,006$); ординату чини дифузиони средњеквадратни губитак уз помоћни губитак фазе. (б) Код *ACT*-а финални губитак (L_1 + помоћни губитак фазе) конвергира ка блиском платоу ($\approx 0,122 \rightarrow 0,114 \rightarrow 0,112$), уз тек благо снижење са обимом података. Апсолутне вредности две ординате нису међусобно упоредиве (различит састав губитка).

5.2 Зависност успешности од броја демонстрација (серија А)


Серија А испитује како перформансе зависе од броја демонстрација за обуку, за обе архитектуре (Ц1, Ц2). Резултати су сажети у Табели 7 и приказани на слици 8. Стопа успешности је у свим конфигурацијама веома ниска. Пилот конфигурације (1 000 демонстрација) не остварују ниједно успешно уметање (0/50 за обе архитектуре), на средњем нивоу (10 000) стопа успешности остаје маргинална (*ACT* 0/50, *DP* 1/50 при *seed*-у 0), а пуне политике преко три *seed*-а (150 епизода) остварују тек по неколико успеха: *ACT* 0,7 % (1 од 150), *Diffusion Policy* 1,3 % (2 од 150). Према томе, на овај задатак се не може прочитати „минималан број демонстрација за прихватљиву стопу успешности” (Ц1): повећање обима података за више од једног реда величине помера стопу успешности тек са нуле на ниво реда 1 % (далеко испод прихватљивог), што је по себи налаз јер горња граница перформанси овде није ограничена првенствено обимом демонстрација. Пошто је стопа успешности веома ниска и слабо дискриминативна, скалирање се јасније читава преко прецизности. Медијана минималне удаљености $d_{\min}$ остаје практично непромењена (плато ≈ 47 mm) са бројем демонстрација и између архитектура (слика 8а), док се јасан ефекат података види у *поравнању са осом* (слика 8б): код *Diffusion Policy* медијана бочног одступања нагло опада и потом сатурира (41,2 $\rightarrow$ 11,9 $\rightarrow$ 11,8 mm за 1 000 $\rightarrow$ 10 000 $\rightarrow$ 30 290 демонстрација), док је код *ACT*-а зашумљена и без монотоног тренда (27,7 $\rightarrow$ 32,9 $\rightarrow$ 21,2 mm). *Diffusion Policy* тако скалира прецизност поравнања предвидивије од *ACT*-а, што је у складу и са нешто вишом стопом успешности на већим скуповима. Обука на пуном скупу код *Diffusion Policy* додатно уклања истеке времена (20 % $\rightarrow$ 0 %) и знатно смањује расипање $d_{\min}$ (међуквartilни распон 42–66 $\rightarrow$ 47–49 mm).

Табела 7: Перформансе у функцији броја демонстрација за обуку ($N = 50$ епизода по тачки, један *seed* евалуације ради упоредивости кроз N ; пуне политике додатно су евалуиране преко три *seed*-а, Табела 8). Стопа успешности је веома ниска у целом опсегу, па су наведене и мере прецизности: медијана и најмања минимална удаљеност врх–лежиште $d_{\min}$ и медијана бочног одступања од осе уметања. Најмање $d_{\min}$ од 2,0 mm (*DP*, 10 000) одговара једном успешном уметању.

Метода	N_{demo}	SR	мед. $d_{\min}$ [mm]	најм. $d_{\min}$ [mm]	мед. бочно [mm]
ACT	1 000	0/50	47,4	16,3	27,7
ACT	10 000	0/50	47,2	20,0	32,9
ACT	30 290	0/50	47,2	19,9	21,2
DP	1 000	0/50	51,6	23,0	41,2
DP	10 000	1/50	46,7	2,0	11,9
DP	30 290	0/50	47,2	14,9	11,8

5.3 Поређење *ACT* и *DP* (серија Б)

Серија Б непосредно пореди две архитектуре обучене на пуном скупу под идентичним условима (Ц2), по стопи успешности и по прецизности $d_{\min}$ и бочног одступања. Збирни приказ дат је у Табели 8; $d_{\min}$ је у оба случаја мерено као растојање врха конектора (*sfp_tip_link*) до лежишта порта, а бочно одступање као нормално растојање врха од осе уметања при најближем приласку. Обе архитектуре имају веома ниску стопу успешности (*ACT* $0,7 \pm 0,9$ %, *DP* $1,3 \pm 1,9$ % преко три *seed*-а) и готово идентичну




Слика 8: Скалирање прецизности са бројем демонстрација за *ACT* и *Diffusion Policy* ($N = 50$ епизода по конфигурацији; тачке су медијане, интервали Q1--Q3). (а) Медијана минималне удаљености $d_{\min}$ врх–лежиште остаје на платоу ≈ 47 mm, готово независно од обима података и архитектуре. (б) Медијана бочног одступања од осе уметања јасно опада са бројем демонстрација, најизраженије код *Diffusion Policy*. Стопа успешности је веома ниска у свим тачкама (пилот 0 %, пуне политике реда 1 %), те није приказана.

медијану $d_{\min}$ (≈ 46 – 47 mm), што потврђује да плато заустављања није својство једне архитектуре. Разлика се јавља у прецизности поравнања: *Diffusion Policy* је боље центриран на осу порта (медијана бочног одступања 9,1 mm, најбоља епизода 0,8 mm) него *ACT* (22,4 mm, односно 1,0 mm), што га на пуном скупу чини ближим геометријском услову за иницијацију уметања; у складу са тим, *DP* остварује и нешто вишу (мада и даље маргиналну) стопу успешности. *ACT*, са друге стране, показује већу варијабилност приласка (шири међуквартилни распон $d_{\min}$).

Табела 8: Поређење *ACT* и *Diffusion Policy* обучених на пуном скупу, преко три *seed*-а евалуације (150 епизода по архитектури). Стопа успешности дата је као средња вредност $\pm$ стандардна девијација преко *seed*-ова; метрике прецизности су над обједињеним епизодама.

Метрика	ACT	DP
Стопа успешности SR	$0,7 \pm 0,9 \%$	$1,3 \pm 1,9 \%$
Медијана $d_{\min}$ [mm]	45,6	47,1
Најмање $d_{\min}$ [mm]	1,2	1,5
Медијана бочног одступања [mm]	22,4	9,1
Најмање бочно одступање [mm]	1,0	0,8

Слика 9 приказује емпиријску расподелу (ECDF) најближег приласка за обе архитектуре обучене на пуном скупу, обједињено преко три *seed*-а (150 епизода по архитектури). Криве се готово поклапају у горњем делу опсега (обе доводе већину епизода до платоа од ≈ 47 mm), а тек мали удео епизода (реда 1 %) досеже праг успеха (≤ 3 mm, осенчено), што одговара ретким успешним уметањима. *Diffusion Policy* има нешто стрмији успон у зони 45–50 mm (уже груписање око платоа), док *ACT* показује дужи доњи реп (више епизода које приђу испод 30 mm, али и више које изразитије промаше).




Слика 9: Емпиријска расподела (ECDF) најближег приласка $d_{\min}$ врх–лежиште за *ACT* и *Diffusion Policy* обучене на пуном скупу, обједињено преко три *seed*-а ($N = 150$ епизода по архитектури). Тек мали удео епизода (реда 1 %) досеже праг успешног уметања (≤ 3 mm, осенчено зелено).

5.4 Анализа грешака и плато перформанси (серија В)

Серија В анализира природу преосталих неуспеха при најбољој постигнутој конфигурацији (обука на пуном скупу, $2 \cdot 10^5$ корака), ради одређивања платоа перформанси (ЦЗ). По типу исхода, при основном *seed*-у свих 50 епизода завршава као *непокретно заустављање* (енгл. *failed_stationary*): робот се задржи непомичан изван циља дуже од 3 s, без иједног истека времена. То је квалитативни напредак у односу на пилот конфигурацију, у којој је 20 % епизода истекло по времену. У огромној већини епизода фаза уметања се не започиње (најбоља дубина уметања 0,0), па је отказ лоциран пре уласка врха у порт; преко три *seed*-а евалуације, међутим, мали удео епизода (реда 1 %) ипак оствари потпуно налегање (дубина $\approx 0,98$, $d_{\min} \approx 1,5$ mm), што показује да завршни маневар није немогућ, већ крајње непоуздан. Видео-снимак једне такве успешне епизоде доступан је путем QR кода на слици 10. Слика 11 приказује расподелу минималне удаљености $d_{\min}$ (врх конектора до лежишта). Изражен је уски *плато заустављања*: 39 од 50 епизода стаје у опсегу 40–50 mm, са медијаном од 47,2 mm, што указује да политика поуздано доводи врх до приближно исте тачке, али не иницира завршни приступ лежишту. Бочно одступање од осе уметања при најближем приласку додатно раслојава неуспехе: 9 епизода добро је поравнато (< 5 mm), 30 умерено (5–20 mm), а 11 изразито промашује осу (≥ 20 mm); медијана бочног одступања износи 11,8 mm. Дакле, доминантни узрок неуспеха није грубо промашивање порта, већ заустављање у фази приласка/поравнања на готово константној удаљености, уз делимично, али недовољно тачно поравнање. Исти плато заустављања јавља се и код *ACT* политике обучене на пуном скупу (медијана $d_{\min} = 47,2$ mm), као и код обе пилот конфигурације, што сугерише да плато перформанси није својство појединачне архитектуре нити пукe количине података, већ структурна граница задатка и постојеће поставке (ЦЗ); чиниоци који је одређују дискутовани су у одељку 6. Збирне метрике *DP* конфигурација дате су

у Табели 9.



<https://youtu.be/SS5MC-dcSX4>

Слика 10: QR код ка видео-снимку успешно изведеног уметања SFP конектора у порт (*Diffusion Policy*; једна од ретких успешних епизода из одељка 5.4). Снимак приказује епизоду из погледа трећег лица, а затим исту епизоду из три камере политике.




Слика 11: Расподела минималне удаљености $d_{\min}$ до циља при најбољој конфигурацији (*Diffusion Policy*, пун скуп, $N = 50$ епизода). Изражен плато заустављања у опсегу 40–50 mm.


Занимљив је однос трајања епизоде и оствареног приласка (слика 12): дуже епизоде систематски приђу ближе лежишту (за пун скуп *Diffusion Policy* Пирсонов коефицијент корелације износи $r \approx -0,37$), што сугерише да политика током дужег извршавања наставља да ситно коригује позу ка циљу, али без прекорачења завршног прага уметања. Квалитативни приказ доминантног режима отказа дат је на слици 13: у обе архитектуре робот доводи врх конектора до непосредне близине порта, али се потом заустави изнад/поред отвора уместо да иницира налегање.

Табела 9: Збирне метрике евалуације *Diffusion Policy* ($N = 50$ епизода, *seed* 0). У обе конфигурације $d_{\min}$ и бочно одступање мерени су од врха конектора (*sfp_tip_link*) до лежишта порта, те су директно упоредиви (пилот конфигурација је накнадно поново евалуирана истом метриком). Приказана стопа успешности односи се на *seed* 0; преко три *seed*-а пуна политика остварује 1,3 % (види Табелу 8).

Метрика	Пилот (1 000)	Пун скуп (30 290)
Стопа успешности	0/50	0/50
Непокретно заустављање	40/50 (80 %)	50/50 (100 %)
Истек времена	10/50 (20 %)	0/50 (0 %)
Медијана $d_{\min}$ [mm]	51,6	47,2
Најмање $d_{\min}$ [mm]	23,0	14,9
Медијана бочног одступања [mm]	41,2	11,8
Просечна дужина епизоде [корака]	1378	600



Слика 12: Дужина епизоде наспрам најближег приласка $d_{\min}$ за *ACT* и *Diffusion Policy* (пун скуп, $N = 50$). Дуже епизоде приђу ближе лежишту.



Слика 13: Режим отказа при најбољим конфигурацијама: репрезентативна епизода за-
уостављања за *ACT* и *Diffusion Policy*, три тренутка (~10 %, ~50 %, ~95 % трајања) из
погледа трећег лица. Врх конектора долази до близине порта, али уметање се не ини-
цира.

6 Дискусија

6.1 Тумачење резултата у односу на циљеве рада

Резултати серија А, Б и В заједнички исцртавају доследну слику: на задатку уметања конектора милиметарске прецизности, обе архитектуре (*ACT*, *Diffusion Policy*), на сва три нивоа величине скупа демонстрација, остварују веома ниску стопу успешности (пилот конфигурације 0/50, а пуне политике тек реда 1 % преко три *seed*-а), уз изразит плато заустављања пре уласка у порт.

Потребан обим демонстрација (Ц1). Пошто је стопа успешности у целом испитаном опсегу (1 000–30 290 демонстрација) веома ниска (највише реда 1 %), оквирни минималан број демонстрација за *прихватљиву* стопу успешности не може се прочитати: он лежи изван испитаног опсега, ако уопште постоји при непромењеној поставци. Повећање обима демонстрација помера стопу успешности тек са нуле на маргиналан ниво, не на употребљив. Ово је само по себи налаз, у складу са запажањима да обим и покривеност демонстрација одређују горњу границу перформанси [5, 6], али са важном квалификацијом: овде повећање обима за више од једног реда величине *не* помера основни исход, што сугерише да доминантно ограничење није количина података, већ природа завршне фазе задатка.

Скалабилност архитектура (Ц2). Иако обе архитектуре деле исти плато заустављања ($d_{\min} \approx 47 \text{ mm}$), њихово понашање са порастом обима података се разликује. *ACT* је на малом скупу (1 000) прецизнији у сировом приласку (медијана $d_{\min}$ 47,4 насупрам 51,6 mm код *DP*) али израженије варира (међуквartilни распон 28–56 mm). *Diffusion Policy*, насупрот томе, из додатних података извлачи првенствено *поравнање*: медијана бочног одступања нагло опада и потом сатурира ($41,2 \rightarrow 11,9 \rightarrow 11,8 \text{ mm}$ за 1 000/10 000/30 290), док је код *ACT*-а зашумљена и без монотонног тренда ($27,7 \rightarrow 32,9 \rightarrow 21,2 \text{ mm}$). На пуном скупу то *DP* чини боље центрираним на осу порта, што је предуслов за иницијацију уметања. Дакле, у погледу скалабилности прецизности поравнања, *Diffusion Policy* боље користи веће скупове података, док *ACT* показује већу почетну ефикасност података уз мању стабилност.

Плато перформанси и његови чиниоци (Ц3). Најинформативнији налаз јесте постојање израженог и робусног платоа: у медијани се врх конектора зауставља на $\approx 47 \text{ mm}$ од лежишта, готово независно од архитектуре и обима података. Отказ је, дакле, доминантно лоциран *пре* уласка врха у порт, у фази терминалног приласка и финог поравнања; тек у уском репу расподеле (реда 1 % епизода) политика доврши налегање, што показује да плато перформанси није апсолутна немогућност већ крајње ниска поузданост завршног маневра. Више чинилаца вероватно доприноси овом платоу: (1) *природа завршне фазе*: прецизно налегање захтева фину корекцију испод милиметра док је конектор у контакту са портом, а клонирање понашања то тешко репродукује јер политика не мери силу контакта нити може да меко попусти при додиру, већ круто прати задату путању; (2) *акумулација грешке и distribution shift* [4]: политика поуздано доводи алат до познате области приласка, али нема покривености стања за завршни, ретко посећени маневар налегања; (3) *простор акција*: управљање преко диференцијалне инверзне кинематике без регулације силе не подржава реактивно попуштање при контакту; (4) *верност опсервација*: демонстрациони скуп снимљен је са неприказаним

врхом конектора, док евалуационо окружење конектор приказује, што уводи умерени померај расподеле на улазним сликама у критичној близини порта. Чињеница да плато не зависи од архитектуре нити количине података снажно сугерише да су доминантни чиниоци (1) и (3), структурни за постојећу поставку, а не капацитет модела.

6.2 Ограничења

Резултате треба тумачити у светлу неколико ограничења. *Прво*, пуне политике евалуиране су преко три *seed*-а евалуације (150 епизода), што стабилизује процену стопе успешности и метрика прецизности; међутим, свака конфигурација обучена је са *једним seed*-ом обуке услед рачунских ограничења, па варијабилност услед случајности саме обуке није процењена. *Друго*, студија је у целости симулациона; трансфер у стварно окружење није испитан. *Треће*, *LeRobot* подразумевано не издваја валидациони подскуп, па је праћен само губитак обуке; његова конвергенција не имплицира генерализацију, што потврђује и веома ниска стопа успешности. *Четврто*, испитана су три нивоа обима података (1 000, 10 000 и 30 290); још финија лествица могла би открити нелинеарности између тих тачака. *Пето*, утицај аугментације и синтетичког шума (првобитно планиран правац) није експериментално изолован, већ је, због архитектурно независног платоа, препуштен будућем раду.

7 Закључак

У овом раду систематски су испитане границе двеју савремених метода учења имитацијама, *ACT* и *Diffusion Policy*, на задатку уметања конектора милиметарске прецизности, у контролисаном симулационом окружењу и над демонстрацијама заједничке *oracle* политике. Поређене су обе архитектуре на три величине скупа демонстрација (1 000, 10 000 и 30 290), уз усклађен буџет обуке (по броју епоха) и идентичан протокол евалуације ($N = 50$ епизода, а пуне политике преко три *seed*-а).

Главни налази, у односу на постављене циљеве, јесу следећи. Стопа успешности је у свим конфигурацијама веома ниска (пилот 0/50, пуне политике реда 1 % преко три *seed*-а), па се минималан број демонстрација за *прихватљиву* стопу успешности не може прочитати у испитаном опсегу, а повећање обима за више од једног реда величине помера стопу успешности тек са нуле на маргиналан ниво (Ц1). Обе архитектуре скалирају прецизност поравнања са бројем демонстрација, при чему *Diffusion Policy* боље користи веће скупове (медијана бочног одступања $41,2 \rightarrow 11,8$ mm, уз засићење већ на 10 000 демонстрација) и на пуном скупу постиже боље центрирање на осу порта, док *ACT* показује већу почетну ефикасност података уз мању стабилност (Ц2). Најзад, идентификован је изражен и архитектурно независан плато перформанси: врх конектора се у медијани зауставља на ≈ 47 mm од лежишта, а отказ је доследно лоциран у фази терминалног приласка и финог поравнања, пре уласка у порт, што указује да доминантно ограничење није капацитет модела нити количина података, већ природа завршне, контактне богате фазе задатка и постојећи простор акција без регулације силе (Ц3).

Из ових налаза произлазе конкретни правци будућег рада. Прво, испитивање утицаја аугментације података и синтетичког шума на робустност (првобитно планиран, а нереализован правац), заједно са усклађивањем верности опсервација између обуке и евалуације (приказ врха конектора при снимању демонстрација). Друго, превазилажење идентификованог платоа перформанси захтева интервенцију у завршној фази: у простор акција треба увести повратну спрегу по сили и управљање које алату дозвољава да меко попусти при контакту (енгл. *compliance*), односно наменски контролер ниског нивоа за завршно налегање уместо чисте диференцијалне инверзне кинематике. Треће, ублажавање акумулације грешке интерактивним учењем (*Dagger* [4]) или резидуалним учењем са појачавањем над ВС политиком, чиме би се покрио ретко посећени маневар налегања. Коначно, финија лествица обима података, понављање обуке преко више *seed*-ова и валидација трансфера на стварном роботском систему заокружили би слику коју ова студија отвара.

Списак слика

1	Архитектура <i>ACT</i> политике	4
2	Архитектура <i>Diffusion Policy</i>	5
3	Ток података кроз систем	8
4	Улазно-излазна шема <i>ACT</i> политике	10
5	Детаљна архитектура <i>Diffusion Policy</i>	11
6	Искоришћеност GPU током обуке	15
7	Криве учења за три величине скупа демонстрација	17
8	Скалирање прецизности са бројем демонстрација	19
9	ECDF најближег приласка $d_{\min}$	20
10	QR код ка видео-снимку успешног уметања	21
11	Расподела $d_{\min}$ при најбољој конфигурацији	21
12	Дужина епизоде наспрам приласка $d_{\min}$	22
13	Режим отказа при најбољим конфигурацијама	23

Списак табела

1	Основне карактеристике скупа демонстрација.	13
2	Хиперпараметри <i>ACT</i> политике. Број корака обуке усклађен је на ≈ 4 епохе за сваку величину скупа ($N_{\text{demo}} = 1\,000/10\,000/30\,290$).	13
3	Хиперпараметри <i>Diffusion Policy</i> . Средњи и пун скуп (10 000/30 290) тренирани су $\approx 1,56$ епохе, док је пилот (1 000) обучен краће ($\approx 0,6$ епоха, batch 32).	14
4	Верзије кључног софтвера и библиотека коришћених у експериментима.	14
5	Трошак обуке по конфигурацији	15
6	Серије експеримената и одговарајући циљеви рада.	16
7	Перформансе у функцији броја демонстрација	18
8	Поређење <i>ACT</i> и <i>Diffusion Policy</i> (пун скуп)	19
9	Збирне метрике евалуације <i>Diffusion Policy</i>	22

Литература

- [1] Tony Z. Zhao и др. „Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware”. У: *Proceedings of Robotics: Science and Systems (RSS)*. 2023. DOI: 10.15607/RSS.2023.XIX.016.
- [2] Cheng Chi и др. „Diffusion Policy: Visuomotor Policy Learning via Action Diffusion”. У: *Proceedings of Robotics: Science and Systems (RSS)*. 2023. DOI: 10.15607/RSS.2023.XIX.026.
- [3] Dean A. Pomerleau. „ALVINN: An Autonomous Land Vehicle In a Neural Network”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 2. 1989., стр. 305–313.
- [4] Stéphane Ross, Geoffrey J. Gordon и J. Andrew Bagnell. „A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning”. У: *Proceedings of the International Conference on Artificial Intelligence and Statistics (AISTATS)*. Сб. 15. 2011., стр. 627–635.
- [5] Ajay Mandlekar и др. „What Matters in Learning from Offline Human Demonstrations for Robot Manipulation”. У: *Proceedings of the Conference on Robot Learning (CoRL)*. 2021.
- [6] Suneel Belkhale, Yuchen Cui и Dorsa Sadigh. „Data Quality in Imitation Learning”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 36. 2023.
- [7] Ashish Vaswani и др. „Attention Is All You Need”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 30. 2017., стр. 5998–6008.
- [8] Kaiming He и др. „Deep Residual Learning for Image Recognition”. У: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016., стр. 770–778.
- [9] Nicolas Carion и др. „End-to-End Object Detection with Transformers”. У: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2020., стр. 213–229.
- [10] Jonathan Ho, Ajay Jain и Pieter Abbeel. „Denoising Diffusion Probabilistic Models”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 33. 2020., стр. 6840–6851.
- [11] Jiaming Song, Chenlin Meng и Stefano Ermon. „Denoising Diffusion Implicit Models”. У: *International Conference on Learning Representations (ICLR)*. 2021.
- [12] Ethan Perez и др. „FiLM: Visual Reasoning with a General Conditioning Layer”. У: *Proceedings of the AAAI Conference on Artificial Intelligence*. 2018., стр. 3942–3951.
- [13] Juan Sanchez и др. „Robotic manipulation and sensing of deformable objects in domestic and industrial settings: a survey”. У: *The International Journal of Robotics Research* 37.7 (2018.), стр. 688–716. DOI: 10.1177/0278364918779698.
- [14] Jonas Spillmann и Matthias Teschner. „CoRdE: Cosserat Rod Elements for the Dynamic Simulation of One-Dimensional Elastic Objects”. У: *Proceedings of the ACM SIGGRAPH/Eurographics Symposium on Computer Animation (SCA)*. 2007., стр. 63–72.
- [15] Oren Spector и Dotan Di Castro. „InsertionNet – A Scalable Solution for Insertion”. У: *IEEE Robotics and Automation Letters* 6.3 (2021.), стр. 5509–5516. DOI: 10.1109/LRA.2021.3076971.

- [16] Olaf Ronneberger, Philipp Fischer и Thomas Brox. „U-Net: Convolutional Networks for Biomedical Image Segmentation”. У: *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2015., стр. 234–241.