



Електротехнички факултет
Универзитет у Београду

Дипломски рад

**Испитивање границе учења
имитацијама у симулационом
окружењу за роботско извршавање
високо прецизних задатака**

Кандидат

Михајло Стевановић

Број индекса: 2022/0315

Ментор

Проф. др Коста Јовановић

22. јун 2026.

Захвалница

Желим да изразим искрену захвалност проф. др Кости Јовановићу на указаном поверењу и прилици да своју студентску праксу, а потом и дипломски рад, реализујем у лабораторији Електротехничког факултета у Палати Науке. Рад у том окружењу пружио ми је непроцењиво практично искуство и непосредан увид у процес научноистраживачког рада.

Посебну захвалност дугујем својим менторима, Давиду Сеничићу и др Филипу Бечановићу, на издвојеном времену, стрпљењу и знању које су несебично делили са мном током рада на овом пројекту. Захваљујући њиховим упутствима, конкретним референцама и правовременим смерницама успео сам да попуним кључне празнине у знању и да рад доведем до краја.

Захваљујем се и свим сарадницима лабораторије за роботiku на колегијалном радном окружењу и свакодневној размени идеја.

Михајло Стевановић
У Београду, јун 2026. године

Садржај

Захвалница	i
1 Увод	1
2 Преглед литературе	3
2.1 Учење имитацијама и клонирање понашања	3
2.2 Action Chunking with Transformers (ACT)	3
2.3 Diffusion Policy	4
2.4 Роботска манипулација деформабилних линеарних објеката	5
3 Методологија	6
3.1 Формулација проблема	6
3.2 Имплементација АСТ политике	8
3.3 Имплементација Дифузионе полисе (Diffusion Policy)	9
4 Експериментална постава	11
4.1 Симулационо окружење	11
4.2 Сензори, опсервације и акције	11
4.3 Хиперпараметри обуке	11
4.4 Протокол евалуације	11
4.5 План експеримената	13
5 Резултати	15
5.1 Криве учења	15
5.2 Зависност успешности од броја демонстрација (серија А)	15
5.3 Поређење АСТ и Diffusion Policy (серија Б)	15
5.4 Утицај аугментације и шума (серија В)	15
5.5 Анализа грешака и плафон перформанси (серија Г)	17
6 Дискусија	18
7 Закључак	18
Списак слика	18
Списак табела	18
Литература	20

1 Увод

Савремена индустријска аутоматизација суочава се са растућом потребом за роботским системима способним да извршавају задатке прецизне монтаже (енгл. *assembly*) које је, до скоро, могуће обавити искључиво уз помоћ руке оператора. Кабловска инфраструктура — конектори, кабловске везице и сродни савитљиви елементи — незаобилазна је у производним линијама аутомобилске, ваздухопловне и медицинске индустрије. Упркос дугогодишњем напретку у роботској манипулацији, аутоматско уметање кабла у конекторски порт остаје нерешен проблем и директно ограничава степен аутоматизације у производним погонима.

Овај задатак представља парадигматски пример такозваног проблема деформабилних линеарних објеката (енгл. *deformable linear objects*, DLO). За разлику од крутих тела, кабл испољава комплексну механику деформације која се не може поуздано унапред предвидети: чак и при идентичним почетним условима, конфигурација кабла у простору варира на начин неподложен аналитичком моделовању. Истовремено, успешна инсерција захтева прецизност на нивоу неколико милиметара, свако одступање завршног механизма (енгл. *end-effector*) изнад те границе резултира неуспехом задатка. Ова комбинација непредвидивости деформације и захтеване прецизности чини аутоматско уметање кабла једним од отворених проблема индустријске роботике.

Овај рад настао је у оквиру учешћа на такмичењу Intrinsic AI for Industry Challenge, које организује компанија Intrinsic (Alphabet Inc.), а које је усмерено на задатке прецизне роботске манипулације у индустријском контексту. За потребе учесника, Intrinsic је обезбедио потпуно конфигурисано симулационо окружење. Оно обухвата платформу NVIDIA Isaac Sim за физичку симулацију и фотореалистично приказивање сцене засновано на графичким процесорима (енгл. *GPU*), уз праћење зрака (енгл. *ray tracing*); OpenUSD склопове за дефиницију сцене, робота и задатка; те Docker контејнер са свим потребним библиотекама унапред инсталираним и међусобно усклађеним, из ког је могуће директно покретати симулације и тренирати политике. Оваква стандардизована поставка елиминисала је проблем конфигурације окружења и обезбедила потпуно репродуцибилне услове за систематско поређење метода.

Класични приступи решавању проблема DLO манипулације заснивају се на експлицитном моделовању геометрије и динамике кабла те планирању путање на основу тог модела. Ови приступи носе високу рачунарску цену и остају осетљиви на грешке услед немоделованог понашања. Као алтернатива, у овом раду истражују се методе *учења имитацијама* (енгл. *imitation learning*, IL) — парадигма у којој агент директно учи политику (пресликавање опсервација у акције) из демонстрација стручног агента, без потребе за експлицитним моделом динамике окружења. Конкретно, поређене су две савремене IL архитектуре: Action Chunking with Transformers (ACT) [1] и Diffusion Policy (DP) [2], обе у формулацији клонирања понашања (енгл. *behavioral cloning*, BC). Скуп демонстрација прикупљен је путем такозване *oracle политике* — скриптованог агента заснованог на коначном аутомату (енгл. *state machine*) коме је, за разлику од тренираних политика, омогућен привилегован приступ апсолутним координатама циљног порта у симулационом окружењу. Ова политика развијена је у оквиру ширег истраживачког пројекта и у овом раду представља фиксну, унапред дату компоненту тока података; њена интерна имплементација стога није предмет ове студије, већ се користи као стандардизован извор демонстрација. Тренирани модели ту информацију не поседују — они уче искључиво из опсервација (RGB слике камере, позиција завршног механизма) и акција које је oracle извршио, чиме је задатак учења реалистично отежан у складу са

ограничењима стварних роботских система.

Централно истраживачко питање рада гласи: *колико далеко, и под којим условима, методе учења имитацијама могу да достигну задовољавајући ниво перформанси на задатку с милиметарском прецизношћу?* Из овог општег питања произлазе четири конкретна истраживачка питања:

1. Колики број демонстрација је неопходан да модел достигне прихватљив проценат успешности (енгл. *success rate*)?
2. Која архитектура — АСТ или DP — боље скалира с величином скупа података за обуку?
3. Какав је утицај аугментације података и синтетичког шума на опсервације на робустност и способност генерализације?
4. Где се налази „плафон” перформанси ових метода на овом типу задатка и шта га детерминише?

Допринос овог рада је троструки. Прво, пружа се систематска експериментална студија граница двеју савремених ИЛ метода на задатку високе прецизности, у контролисаном симулационом окружењу и над демонстрацијама прикупљеним заједничком огасле политиком. Друго, анализира се зависност перформанси од величине скупа података и одређује оквирни минималан број демонстрација неопходан за прихватљив проценат успешности. Треће, квантификује се утицај аугментације и додатог шума на перформансе, пружајући смернице за практичну примену ИЛ метода у индустријским условима.

Рад је организован на следећи начин. Поглавље 2 даје преглед релевантне литературе из области учења имитацијама, са посебним освртом на АСТ и Diffusion Policy, као и сродне радове о роботској манипулацији деформабилним објектима. У Поглављу 3 описују се формулација проблема, архитектуре модела и ток података, укључујући заједничку огасле политику као контекст у коме настаје скуп демонстрација. Поглавље 4 детаљно излаже симулационо окружење, простор опсервација и акција, хиперпараметре и метрике евалуације. Резултати свих експерименталних димензија приказани су у Поглављу 5, а њихова интерпретација и ограничења дискутовани у Поглављу 6. Поглавље 7 доноси закључна разматрања и правце будућих истраживања.

2 Преглед литературе

2.1 Учење имитацијама и клонирање понашања

Учење имитацијама (IL) је парадигма у оквиру које агент стиче политику π опонашањем стручног демонстратора, без директног дефинисања функције награде окружења. Најједноставнији облик IL-а је клонирање понашања (BC), уведено у контексту аутономне навигације у систему ALVINN [3]. У BC формулацији, политика се тренира надгледаним учењем на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$:

$$\pi^* = \arg \min_{\pi} \mathbb{E}_{(\mathbf{o}, \mathbf{a}) \sim \mathcal{D}} [\mathcal{L}(\pi(\mathbf{o}), \mathbf{a})], \quad (1)$$

где $\mathbf{o}$ означава опсервацију, $\mathbf{a}$ акцију стручног агента, а $\mathcal{L}$ критеријумску функцију губитка.

Кључно ограничење BC-а је проблем акумулације грешке: мала одступања у предвиђеним акцијама нагомиланим ефектом одводе агента у стања која нису покривена скупом демонстрација, а политика нема усвојеног понашања за реоријентацију и поправку из таквих стања. Овај феномен, познат као *distribution shift*, математички је формализовао Ross et al. [4], а у истом раду предложен је алгоритам DAgger (Dataset Aggregation) — итеративни поступак обогаћивања скупа демонстрација стањима насталим током евалуације (енгл. *rollout-a*) тренираног агента. Свеобухватна студија Mandlekar et al. [5] на скупу референтних задатака Robomimic (енгл. *benchmark*) показала је да на успешност BC-а у роботској манипулацији пресудно утичу квалитет и покривеност простора стања у демонстрацијама, а не искључиво архитектура модела.


2.2 Action Chunking with Transformers (ACT)

ACT је метода учења имитацијама коју су предложили Zhao et al. [1] за задатке прецизне биманипулације. Централни допринос је концепт *action chunking*-а: уместо предвиђања јединичне акције у сваком временском кораку, политика предвиђа блок (chunk) од k узастопних акција $(\mathbf{a}_t, \mathbf{a}_{t+1}, \dots, \mathbf{a}_{t+k-1})$. Ефективни хоризонт задатка тако се смањује за фактор k , чиме се директно ублажава проблем акумулације грешке [4] — уместо T независних одлука политика доноси свега $\lceil T/k \rceil$.

Архитектура ACT-а комбинује условни варијациони аутоенкодер (CVAE) и кодер-декодер трансформер (Сл. 1):

- **CVAE кодер** (активан искључиво током тренинга): прима секвенцу акција из демонстрације и тренутне позиције зглобова, те их сажима у латентну променљиву $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$. Улога CVAE-а је моделовање вишемодалности у демонстрацијама — различити стилови извршавања истог задатка кодирају се у различите вредности $\mathbf{z}$. У фази примене, CVAE кодер се изоставља, а вредност латентног вектора $\mathbf{z}$ поставља на нулу.
- **Трансформерски декодер**: прима визуелне карактеристике N RGB камера (кодоване ResNet-18 кичмом), позиције зглобова и $\mathbf{z}$, те унакрсним механизмом пажње генерише предвиђени блок акција. Дизајн декодера заснован је на DETR архитектури са учивим позиционим кодовима у улози упитних вектора.

Критеријумска функција током тренинга комбинује L1 реконструкцијску грешку и KL регуларизацију:



Слика 1: Архитектура АСТ политике: CVAE кодер (лево) сажима секвенцу акција и позиције зглобова у латентну променљиву $\mathbf{z}$, док трансформерски кодер-декодер (десно) на основу слика камера, позиција зглобова и $\mathbf{z}$ предвиђа секвенцу акција. Преузето из [1].

$$\mathcal{L}_{\text{ACT}} = \mathbb{E}[\|\hat{\mathbf{a}} - \mathbf{a}\|_1] + \beta \cdot D_{\text{KL}}(\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2 \mathbf{I}) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})), \quad (2)$$

где је β хиперпараметар (подразумевано $\beta = 10$) који уравнотежује прецизност предвиђања и регуларизацију латентног простора.

За глаткост покрета при преклапајућим акцијским блоковима, АСТ опционо примењује временско усредњавање (енгл. *temporal ensembling*): предвиђања за исти тренутак из вишеструких узастопних читавања политике комбинују се са експоненцијалним тежинама $w_i = e^{-m \cdot i}$. На задацима прецизне биманипулације у физичком окружењу АСТ постиже успешност 80–96% [1], уз значајно надмашивање референтних метода BC-ConvMLP, BeT и VINN. Аблациона студија у истом раду показала је да само повећање величине блока са $k=1$ на $k=100$ побољшава успешност са 1% на 44% на репрезентативном задатку биманипулације.

2.3 Diffusion Policy

Diffusion Policy (DP) је метода учења политике коју су увели Chi et al. [2], заснована на одшумљавању дифузијским вероватносним моделима (DDPM) [6] примењеним на простор акција роботске политике. Кључна идеја је представљање условне расподеле акција $p(\mathbf{A}_t \mid \mathbf{O}_t)$ кроз итеративни поступак уклањања шума:


$$\mathbf{x}^{(k-1)} = \alpha(\mathbf{x}^{(k)} - \gamma \epsilon_{\theta}(\mathbf{x}^{(k)}, k, \mathbf{O}_t)) + \boldsymbol{\eta}, \quad \boldsymbol{\eta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}), \quad (3)$$

где $\mathbf{x}^{(K)}$ представља иницијални Гаусов шум, а ϵ_{θ} мрежу тренирану да предвиди шум условљен опсервацијом $\mathbf{O}_t$. Поступак поступно претвара насумичан шум у кохерентан акцијски план кроз K корака одшумљавања. Применом DDIM [7] шеме потребан број ових корака смањује се са 100 на свега 10, чиме се постиже кашњење испод 0,1 с при примени политике на GPU.

DP такође предвиђа секвенце акција (T_p корака), али извршава само $T_a < T_p$ пре следеће активације политике, остварујући баланс дугорочног планирања и брзе реакције на тренутне опсервације. Предложена су два архитектурална варијанта (Сл. 2):

- **Conv-DP**: 1D временске конволуције са Feature-wise Linear Modulation (FiLM) за условљавање опсервацијама; поуздан у широком спектру задатака.

- **Trans-DP**: transformer decoder блокови са каузалним маскирањем пажње; надмашује Conv-DP на задацима са нагло променљивим и вишемодалним акцијама.



Слика 2: Архитектура Diffusion Policy: слике три камере и проприоцептивни вектор кодирају се у условни вектор опсервације $\mathbf{O}_t$, којим се FiLM модулацијом условљава мрежа ϵ_θ (1D U-Net); акцијска секвенца настаје итеративним одшумљавањем почетног Гаусовог шума кроз K корака. Прилагођено из [2].

Евалуација на 15 задатака из четири скупа референтних задатака (укључујући Robomimic [5]) показала је просечно унапређење од 46,9% у односу на претходне BC методе [2]. Кључна предност DP-а у односу на детерминистичке регресионе политике је природна способност моделовања вишемодалних расподела акција: у ситуацијама са вишеструким оптималним путањама DP не пати од колапса мода (енгл. *mode collapse*).

2.4 Роботска манипулација деформабилних линеарних објеката

Деформабилни линеарни објекти (DLO) — жице, каблови и слични савитљиви елементи — представљају засебну и отворену класу проблема у роботској манипулацији [8]. За разлику од крутих тела, чији је положај у потпуности одређен шест степени слободе, стање DLO-а захтева опис бесконачно-димензионог конфигурационог простора деформације. Аналитичко моделовање ове динамике носи висок рачунарски захтев и оставља значајне немоделоване ефекте услед трења, вискоеластичности материјала и контакта са окружењем [8].

Традиционални приступи манипулацији DLO-а ослањали су се на сензоре силе и момента или на физичке моделе засноване на Косератовој (енгл. *Cosserat*) теорији еластичних штапова, постижући ограничену применљивост у условима непредвидивих деформација. Задатак инсерције кабла у конекторски порт додатно захтева прецизност на нивоу неколико милиметара — свако одступање завршног механизма изнад овог прага резултира механичким неуспехом. Ова комбинација непредвидивости деформације и захтеване прецизности чини инсерцију кабла репрезентативним примером задатка за који методе засноване на моделски-слободном учењу из демонстрација — какве су АСТ и DP — представљају природну алтернативу приступима заснованим на експлицитном моделу динамике.

3 Методологија

Методолошки оквир рада обухвата четири целине: прикупљање демонстрација заједничком огасе политиком, формирање скупа демонстрација у LeRobot формату, тренинг политика клонирањем понашања и евалуацију у симулационом окружењу. Прве две целине — огасе политика и формирање скупа — развијене су у оквиру ширег пројекта и овде се приказују само на нивоу тока података, ради потпуности; тежиште овог рада су треће и четврта целина, односно обука и систематска евалуација ИЛ политика. Кључна одлика поставе је асиметрија информација: огасе политика има приступ апсолутним координатама порта, док трениране политике одлучују искључиво на основу опсервација. Целокупан ток података приказан је на слици 3.

3.1 Формулација проблема

Задатак разматран у овом раду је аутономна инсерција кабла у конекторски порт у симулационом окружењу са шестоосним роботом UR5e. Политика управља роботом на фреквенцији од 30 Hz и у сваком дискретном тренутку t прима опсервацију $\mathbf{o}_t$ и одређује акцију $\mathbf{a}_t$.

Простор опсервација. Опсервација у тренутку t састоји се од визуелне и проприоцептивне компоненте:

$$\mathbf{o}_t = (\mathbf{I}_t^c, \mathbf{I}_t^l, \mathbf{I}_t^r, \mathbf{s}_t), \quad (4)$$


где $\mathbf{I}_t^c, \mathbf{I}_t^l, \mathbf{I}_t^r \in \mathbb{R}^{H \times W \times 3}$ означавају RGB слике централне, леве и десне камере, а $\mathbf{s}_t \in \mathbb{R}^{56}$ проприоцептивни вектор стања добијен конкатенацијом следећих величина (све изражене у базном координатном систему робота):

- $\mathbf{q}_t, \dot{\mathbf{q}}_t, \boldsymbol{\tau}_t \in \mathbb{R}^6$ — позиције, брзине и моменти шест зглобова роботске руке,
- $\mathbf{p}_t^{\text{tcp}} \in \mathbb{R}^3, \mathbf{r}_t^{\text{tcp}} \in \mathbb{R}^4$ — позиција и оријентација (кватернион) радне тачке алата (TCP),
- $\mathbf{p}_t^{\text{eef}} \in \mathbb{R}^3, \mathbf{r}_t^{\text{eef}} \in \mathbb{R}^4$ — позиција и оријентација референтног оквира хватача,
- $\mathbf{v}_t^{\text{tcp}}, \boldsymbol{\omega}_t^{\text{tcp}}, \mathbf{v}_t^{\text{eef}}, \boldsymbol{\omega}_t^{\text{eef}} \in \mathbb{R}^3$ — линеарне и угаоне брзине TCP-а и хватача,
- $\mathbf{w}_t \in \mathbb{R}^6$ — сила и момент на завршном зглобу хватача (wrist wrench),
- $\mathbf{a}_{t-1} \in \mathbb{R}^6$ — акција примењена у претходном временском кораку.

Кључно ограничење реалистичности задатка: политика не прима апсолутне координате циљног порта. Та информација је доступна искључиво огасе политици коришћеној за генерисање скупа демонстрација $\mathcal{D}$.

Простор акција. Акција политике у сваком временском кораку је прираст позе TCP-а у картезијанском простору, изражен као шестодимензиони вектор:

$$\mathbf{a}_t = (\Delta \mathbf{p}_t, \Delta \boldsymbol{\theta}_t) \in \mathbb{R}^6, \quad (5)$$



Слика 3: Ток података кроз систем: oracle политика са приступом координатама порта генерише демонстрације преко коначног аутомата и DiffIK управљача, успешне епизоде се чувају у LeRobot скуп демонстрација, на коме се тренирају ACT и Diffusion Policy политике, а потом евалуирају без привилеговане информације.

где $\Delta \mathbf{p}_t \in \mathbb{R}^3$ означава трансляциони прираст, а $\Delta \boldsymbol{\theta}_t \in \mathbb{R}^3$ ротациони прираст у форми вектора ротације (оса--угао). Излаз политике у опсегу $[-1, 1]$ скалира се пре прослеђивања управљачу, чиме се трансляциони прираст по кораку ограничава на 1,5 cm, а ротациони на 0,025 rad по оси. Овако скалирани прираст прослеђује се управљачу заснованом на диференцијалној инверзној кинематици (DiffIK), који методом пригушених најмањих квадрата (енгл. *damped least squares*, DLS) рачуна одговарајуће циљне позиције зглобова робота. Хватач је током целог задатка у затвореном положају, па акција не обухвата управљачку променљиву прстију хватача.

Формулација клонирања понашања. Задатак учења формулише се у оквиру клонирања понашања (1): политика π_θ тренира се на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$ генерисаних огасле политиком, надгледаном минимизацијом грешке предвиђене акције. Оба архитектурална варијанта разматрана у овом раду — АСТ и Diffusion Policy — тренирана су у идентичном ВС оквиру на заједничком скупу демонстрација, чиме је обезбеђена поредивост резултата.

Метрике евалуације. Успешност политике мери се двама метрикама. Примарна је бинарна стопа успешности:

$$\text{SR} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\text{епизода } i \text{ успешна}], \quad (6)$$

где N означава укупан број евалуационих епизода. Епизода се сматра успешном ако врх за уметање достигне циљну позу — истовремено позициону грешку не већу од 3 mm и угаону грешку не већу од 4° — и ту позу задржи најмање 0,5 s, чиме се елиминишу пролазни додири без стварне инсерције. Секундарна метрика је минимална еуклидска удаљеност врха за уметање од циљне позиције инсерције током епизоде:

$$d_{\min} = \min_{t \in [1, T]} \|\mathbf{p}_t^{\text{tip}} - \mathbf{p}^*\|_2, \quad (7)$$

где $\mathbf{p}_t^{\text{tip}} \in \mathbb{R}^3$ означава позицију врха за уметање у тренутку t , а $\mathbf{p}^* \in \mathbb{R}^3$ циљну позицију инсерције. Метрика $d_{\min}$ омогућава квантификацију прецизности грешке и у неуспелим епизодама, пружајући финији увид у ниво перформанси изван бинарног критеријума (6).

3.2 Имплементација АСТ политике


Архитектура АСТ-а, описана у одељку 2.2, у овом раду инстанцирана је коришћењем имплементације из библиотеке LeRobot. Политика прима опсервацију $\mathbf{o}_t$ из (4) и предвиђа блок од k узастопних акција у простору (5), што је приказано на слици 4.

Визуелни део опсервације — слике три камере — кодира се ResNet-18 кичмом, чији излаз чини скуп просторних токена за трансформерски декодер. Проприоцептивни вектор $\mathbf{s}_t$ пројектује се линеарним слојем у засебан улазни токен. CVAE кодер активан је искључиво током тренинга и моделује вишемодалност демонстрација кроз латентну променљиву $\mathbf{z}$, док се у фази примене поставља $\mathbf{z} = \mathbf{0}$. Тренинг се води минимизацијом комбиноване функције губитка (2).

У односу на изворну формулацију, имплементација у овом раду проширена је помоћном главом за класификацију фазе задатка: линеарни слој над усредњеном репрезентацијом кодера предвиђа тренутну фазу извршавања (ПРИЛАЗАК, ПОРАВНАЊЕ

или УМЕТАЊЕ). Ова глава се тренира унакрсном ентропијом као помоћним губитком са тежином 0,1, чиме се репрезентација подстиче да издвоји обележја информативна о напретку задатка, без утицаја на излаз политике у фази примене.

Ради повећања робусности на варијације осветљења и положаја камере, на улазне слике се током тренинга примењују фотометријске и геометријске аугментације. У фази примене политика користи временско усредњавање, чиме се преклапајућа предвиђања акцијских блокова комбинују у глатку управљачку секвенцу. Конкретне вредности хиперпараметара (величина блока k , тежина β , стопа учења и параметри аугментације) наведене су у одељку 4.




Слика 4: Улазно-излазна шема АСТ политике примењене у овом раду: слике три камере (ResNet-18) и проприоцептивни вектор s_t (линеарни слој), уз латентну променљиву z , улазе у трансформерски енкодер--декодер који предвиђа блок од k акција. У фази примене $z = \mathbf{0}$ и примењује се временско усредњавање.

3.3 Имплементација Дифузионе полисе (Diffusion Policy)

Diffusion Policy инстанцирана је такође у оквиру библиотеке LeRobot, на истом скупу демонстрација $\mathcal{D}$ и са идентичним простором опсервација (4) и акција (5) као АСТ (Сл. 5), чиме је обезбеђена поредивост двеју метода.

Коришћена је конволуциона варијанта (Conv-DP): мрежа за одшумљавање заснована је на једнодимензионом U-Net-у, а условљавање опсервацијом остварено је FiLM модулацијом. Сlike три камере кодирају се ResNet-18 кичмом, а добијени визуелни дескриптори се заједно са проприоцептивним вектором s_t сажимају у условни вектор опсервације $\mathbf{O}_t$. Мрежа ϵ_θ тренира се да предвиди шум додат на акцијску секвенцу, у складу са (3), минимизацијом средње квадратне грешке предвиђеног шума. Као и код АСТ политике, додата је помоћна глава за класификацију фазе задатка (ПРИЛАЗАК, ПОРАВЊАЊЕ, УМЕТАЊЕ), тренирана унакрсном ентропијом са тежином 0,1 над условним вектором опсервације, ради конзистентности поставке двеју метода.

У фази примене, акцијска секвенца се генерише итеративним одшумљавањем из Гаусовог шума, условљеним текућом опсервацијом, при чему се користи DDIM шема ради смањења броја корака одшумљавања. Политика предвиђа секвенцу од T_p корака, а извршава њених првих $T_a < T_p$ пре поновне активације (рецидирајући хоризонт). Вредности хиперпараметара (хоризонти T_p и T_a , број корака одшумљавања, стопа учења) дате су у одељку 4.



Слика 5: Улазно-излазна шема Diffusion Policy примењене у овом раду: текућа опсервација $\mathbf{O}_t$ условљава итеративно одшумљавање које из Гаусовог шума генерише секвенцу од T_p акција; извршава се само првих T_a корака, након чега се поступак понавља са новом опсервацијом (рецидирајући хоризонт).

4 Експериментална постава

Ово поглавље описује симулационо окружење, конфигурацију сензора и управљача, хиперпараметре обуке обеју политика и протокол евалуације. Циљ је да постава буде описана довољно детаљно да омогући репродукцију резултата.

4.1 Симулационо окружење

Сви експерименти изведени су у симулатору Isaac Lab, надградњи платформе NVIDIA Isaac Sim, у оквиру задатка регистрованог под идентификатором AIC-Port-Insertion-v0. Задатак је реализован као окружење засновано на менаџерима (енгл. *manager-based*), где су сцена, опсервације, акције, догађаји и услови завршетка епизоде дефинисани засебним конфигурационим модулима.

Робот је шестоосни UR5e, монтиран са ротацијом од 180° око вертикалне осе радне површине; услед тога се проприоцептивне величине изражавају у координатном систему базе робота (енгл. *root frame*), који одговара ономе што робот „види” путем директне кинематике. Физичка симулација извршава се кораком $\Delta t_{\text{sim}} = 1/120 \text{ s}$, док се управљачка петља покреће на сваки четврти физички корак (фактор редукције 4), што даје ефективну фреквенцију политике од 30 Hz. Максимално трајање епизоде износи 120 s, односно до 3600 управљачких корака. Сцена је осветљена куполним светлом чији се интензитет и положај насумично варирају између епизода (енгл. *domain randomization*), ради робусности на услове осветљења.

4.2 Сензори, опсервације и акције

Визуелну опсервацију чине три RGB камере (централна, лева и десна), реализоване као TiledCamera са пинхол моделом пројекције, резолуције 224×224 пиксела и жижне даљине 22,48 mm. Слике се прослеђују политици у изворном осмобитном формату (без нормализације на нивоу окружења). Проприоцептивни вектор $\mathbf{s}_t \in \mathbb{R}^{56}$ и простор акција $\mathbf{a}_t \in \mathbb{R}^6$ дефинисани су у одељку 3.1; излаз политике у опсегу $[-1, 1]$ скалира се на највише 1,5 cm translације и 0,025 rad ротације по управљачком кораку.

Поред опсервационе групе доступне политици, окружење дефинише и привилеговану групу (енгл. *cheatcode*) која садржи апсолутне координате улаза и лежишта порта те фракцију уметнутости. Ова група служи искључиво oracle политици при генерисању демонстрација и није доступна трениране политикама током евалуације, чиме се остварује описана асиметрија информација.

4.3 Хиперпараметри обуке

Обе политике трениране су у оквиру библиотеке LeRobot, на заједничком скупу демонстрација и са идентичним простором опсервација и акција. Хиперпараметри АСТ политике дати су у Табели 1, а Diffusion Policy у Табели 2. Вредности означене са (*допунити*) биће утврђене из коначних трениншких конфигурација.

4.4 Протокол евалуације

Сваки трениран модел евалуира се на $N = (\text{допунити})$ независних епизода са насумичним почетним условима, без приступа привилегованим координатама порта. Пер-

Табела 1: Хиперпараметри АСТ политике.

Хиперпараметар	Вредност
Визуелна кичма	ResNet-18
Величина акцијског блока k	(допунити)
Тежина KL члана β	10
Димензија модела	512
Број глава пажње	8
Слојеви кодера / декодера	4 / 1
Темпорално усредњавање (примена)	да
Тежина помоћног губитка фазе	0,1
Оптимизатор	Adam
Стопа учења	(допунити)
Величина серије (batch)	(допунити)
Број корака обуке	(допунити)

Табела 2: Хиперпараметри Diffusion Policy.

Хиперпараметар	Вредност
Визуелна кичма	ResNet-18
Архитектура мреже за одшумљавање	1D U-Net
Условљавање опсервацијом	FiLM
Број опсервационих корака n_{obs}	2
Хоризонт предвиђања T_p	16
Хоризонт извршавања T_a	8
Исечак слике (random crop)	216×216
Распоред шума (енгл. <i>noise schedule</i>)	squaredcos_cap_v2
Циљ предвиђања	шум (ϵ)
Број корака дифузије (обука)	100
Број корака одшумљавања (примена, DDIM)	(допунити)
Тежина помоћног губитка фазе	0,1
Оптимизатор	Adam
Стопа учења	$1 \cdot 10^{-4}$
Величина серије (batch)	(допунити)
Број корака обуке	(допунити)

формансе се изражавају стопом успешности (6) и минималном удаљеношћу врха за уметање од циља (7). Епизода се сматра успешном када врх за уметање задржи позициону грешку испод 3 mm и угаону грешку испод 4° најмање 0,5 s; епизода се означава неуспелом по истеку времена или када робот остане непокретан изван циља дуже од 1 s. Скуп демонстрација садржи (*допунити*) успешних епизода прикупљених oracle политиком, а утицај његове величине на перформансе анализира се у Поглављу 5.

4.5 План експеримената

Експерименти су осмишљени тако да дају директан одговор на четири истраживачка питања постављена у Уводу. Заједничка основа свих експеримената је иста: исто симулационо окружење, исти простор опсервација и акција, заједнички извор демонстрација и идентичан протокол евалуације из одељка 4.4. Варира се само мали скуп контролисаних чинилаца, чиме се изоловано мери ефекат сваког од њих.

Независне променљиве. Систематски се варирају следећи чиниоци:

- **Архитектура политике** — АСТ или Diffusion Policy, под иначе идентичним условима;
- **Величина скупа демонстрација** — број епизода за обуку $N_{\text{demo}} \in \{\text{допунити}\}$ (нпр. растућа лествица од неколико десетина до неколико стотина епизода);
- **Аугментација података** — укључена или искључена (фотометријске и геометријске трансформације улазних слика);
- **Ниво синтетичког шума** — стандардна девијација шума додатог на опсервације, $\sigma \in \{\text{допунити}\}$.

Контролисане (фиксне) променљиве. Симулационо окружење, конфигурација сензора, простор опсервација и акција, скуп хиперпараметара архитектуре (Табеле 1 и 2), као и протокол евалуације држе се непроменљивим током поређења, како би уочене разлике у перформансама биле приписиве искључиво независним променљивим.

Понављања и извештавање. Свака конфигурација понавља се са $K = (\text{допунити})$ различитих насумичних семена (енгл. *seed*) ради процене варијабилности. Резултати се изражавају као средња вредност стопе успешности уз стандардну девијацију преко семена, док се расподела величине d_{min} користи за финалију анализу прецизности и типова грешке.

Серије експеримената и њихово мапирање на истраживачка питања сажети су у Табели 3.

Табела 3: Серије експеримената и одговарајућа истраживачка питања.

Серија	Варирана променљива	Истраживачко питање
А	величина скупа демонстрација	РП1, РП2
Б	архитектура (АСТ / DP)	РП2
В	аугментација и ниво шума	РП3
Г	анализа грешака при најбољој конфигурацији	РП4

Серија А утврђује зависност стопе успешности од броја демонстрација за обе архитектуре и тиме одговара на питање о потребном обиму података (РП1) и о томе која метода боље скалира (РП2). Серија Б продубљује директно поређење АСТ и DP при једнаким условима. Серија В изолује допринос аугментације и отпорност на синтетички шум (РП3). Коначно, серија Г анализира природу преосталих неуспеха при најбољој постигнутој конфигурацији — расподелу $d_{\min}$ и фазу задатка у којој долази до отказа — ради одређивања плафона перформанси и чинилаца који га детерминишу (РП4).

5 Резултати

Резултати су организовани по серијама експеримената из одељка 4.5. Све вредности добијене су по протоколу евалуације из одељка 4.4 — стопа успешности извештава се као средња вредност преко K семена уз стандардну девијацију, а прецизност преко расподеле минималне удаљености $d_{\min}$.

5.1 Криве учења

Слика 6 приказује кретање функције губитка током обуке за обе архитектуре, чиме се потврђује конвергенција и одсуство презасићења (енгл. *overfitting*) пре евалуације.



Слика 6: Криве учења АСТ и Diffusion Policy политика током обуке.

5.2 Зависност успешности од броја демонстрација (серија А)

Серија А испитује како стопа успешности расте са бројем демонстрација за обуку, за обе архитектуре (РП1, РП2). Резултати су сажети у Табели 4 и приказани на слици 7, где се може прочитати оквирни минималан број демонстрација потребан за прихватљив проценат успешности.

Табела 4: Стопа успешности у функцији броја демонстрација за обуку.


Број демонстрација N_{demo}	SR (ACT)	SR (DP)
(допунити)	(допунити)	(допунити)
(допунити)	(допунити)	(допунити)
(допунити)	(допунити)	(допунити)

5.3 Поређење АСТ и Diffusion Policy (серија Б)

Серија Б непосредно пореди две архитектуре под идентичним условима (РП2), и по стопи успешности и по прецизности $d_{\min}$. Збирни приказ дат је у Табели 5.

5.4 Утицај аугментације и шума (серија В)


Серија В квантификује допринос аугментације података и отпорност на синтетички шум на опсервацијама (РП3). Слика 8 приказује стопу успешности у функцији нивоа шума, са и без аугментације.



Слика 7: Стопа успешности у функцији величине скупа демонстрација за ACT и Diffusion Policy.

Табела 5: Поређење ACT и Diffusion Policy при једнаким условима обуке.


Метрика	ACT	DP
Стопа успешности SR	(допунити)	(допунити)
Медијана $d_{\min}$ [mm]	(допунити)	(допунити)
Кашњење у примени [ms]	(допунити)	(допунити)



Слика 8: Утицај аугментације и нивоа синтетичког шума на стопу успешности.

5.5 Анализа грешака и плафон перформанси (серија Г)

Серија Г анализира преостале неуспехе при најбољој постигнутој конфигурацији (РП4). Слика 9 приказује расподелу минималне удаљености $d_{\min}$ у успешим и неуспешим епизодама, а Табела 6 расподелу отказа по фазама задатка (ПРИЛАЗАК, ПОРАВНАЊЕ, УМЕТАЊЕ), чиме се идентификује доминантни узрок неуспеха.



Слика 9: Расподела минималне удаљености $d_{\min}$ до циља при најбољој конфигурацији.

Табела 6: Расподела неуспеха по фазама задатка при најбољој конфигурацији.

Фаза задатка	Удео неуспеха [%]
ПРИЛАЗАК	(допунити)
ПОРАВНАЊЕ	(допунити)
УМЕТАЊЕ	(допунити)

6 Дискусија

7 Закључак

Списак слика

1	Архитектура АСТ политике: CVAE кодер (лево) сажима секвенцу акција и позиције зглобова у латентну променљиву $\mathbf{z}$, док трансформерски кодер-декодер (десно) на основу слика камера, позиција зглобова и $\mathbf{z}$ предвиђа секвенцу акција. Преузето из [1].	4
2	Архитектура Diffusion Policy: слике три камере и проприоцептивни вектор кодирају се у условни вектор опсервације $\mathbf{O}_t$, којим се FiLM модулацијом условљава мрежа ϵ_θ (1D U-Net); акцијска секвенца настаје итеративним одшумљавањем почетног Гаусовог шума кроз K корака. Прилагођено из [2].	5
3	Ток података кроз систем: oracle политика са приступом координатама порта генерише демонстрације преко коначног аутомата и DiffIK управљача, успешне епизоде се чувају у LeRobot скуп демонстрација, на коме се тренирају АСТ и Diffusion Policy политике, а потом евалуирају без привилеговане информације.	7
4	Улазно-излазна шема АСТ политике примењене у овом раду: слике три камере (ResNet-18) и проприоцептивни вектор $\mathbf{s}_t$ (линеарни слој), уз латентну променљиву $\mathbf{z}$, улазе у трансформерски енкодер–декодер који предвиђа блок од k акција. У фази примене $\mathbf{z} = \mathbf{0}$ и примењује се временско усредњавање.	9
5	Улазно-излазна шема Diffusion Policy примењене у овом раду: текућа опсервација $\mathbf{O}_t$ условљава итеративно одшумљавање које из Гаусовог шума генерише секвенцу од T_p акција; извршава се само првих T_a корака, након чега се поступак понавља са новом опсервацијом (рецидирајући хоризонт).	10
6	Криве учења АСТ и Diffusion Policy политика током обуке.	15
7	Стопа успешности у функцији величине скупа демонстрација за АСТ и Diffusion Policy.	16
8	Утицај аугментације и нивоа синтетичког шума на стопу успешности.	16
9	Расподела минималне удаљености $d_{\min}$ до циља при најбољој конфигурацији.	17

Списак табела

1	Хиперпараметри АСТ политике.	12
2	Хиперпараметри Diffusion Policy.	12
3	Серије експеримената и одговарајућа истраживачка питања.	13
4	Стопа успешности у функцији броја демонстрација за обуку.	15
5	Поређење АСТ и Diffusion Policy при једнаким условима обуке.	16
6	Расподела неуспеха по фазама задатка при најбољој конфигурацији.	17

Литература

- [1] Tony Z. Zhao и др. „Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware”. У: *Proceedings of Robotics: Science and Systems (RSS)*. 2023. doi: 10.15607/RSS.2023.XIX.016.
- [2] Cheng Chi и др. „Diffusion Policy: Visuomotor Policy Learning via Action Diffusion”. У: *Proceedings of Robotics: Science and Systems (RSS)*. 2023. doi: 10.15607/RSS.2023.XIX.026.
- [3] Dean A. Pomerleau. „ALVINN: An Autonomous Land Vehicle In a Neural Network”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 2. 1989., стр. 305–313.
- [4] Stéphane Ross, Geoffrey J. Gordon и J. Andrew Bagnell. „A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning”. У: *Proceedings of the International Conference on Artificial Intelligence and Statistics (AISTATS)*. Сб. 15. 2011., стр. 627–635.
- [5] Ajay Mandlekar и др. „What Matters in Learning from Offline Human Demonstrations for Robot Manipulation”. У: *Proceedings of the Conference on Robot Learning (CoRL)*. 2021.
- [6] Jonathan Ho, Ajay Jain и Pieter Abbeel. „Denoising Diffusion Probabilistic Models”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 33. 2020., стр. 6840–6851.
- [7] Jiaming Song, Chenlin Meng и Stefano Ermon. „Denoising Diffusion Implicit Models”. У: *International Conference on Learning Representations (ICLR)*. 2021.
- [8] Juan Sanchez и др. „Robotic manipulation and sensing of deformable objects in domestic and industrial settings: a survey”. У: *The International Journal of Robotics Research* 37.7 (2018.), стр. 688–716. doi: 10.1177/0278364918779698.