



Електротехнички факултет
Универзитет у Београду

Дипломски рад

**Испитивање границе учења
имитацијама у симулационом
окружењу за роботско извршавање
високо прецизних задатака**

Михајло Стевановић
Број индекса: 2022/0315

Ментор
Проф. др Коста Јовановић

18. јун 2026.

Захвалница

Желим да изразим искрену захвалност проф. др Кости Јовановићу на указаном поверењу и прилици да своју студентску праксу, а потом и дипломски рад, реализујем у лабораторији Електротехничког факултета у Палати Науке. Рад у том окружењу пружио ми је непроцењиво практично искуство и непосредан увид у процес научноистраживачког рада.

Посебну захвалност дугујем својим менторима, Давиду Сеничићу и др Филипу Бечановићу, на издвојеном времену, стрпљењу и знању које су несебично делили са мном током рада на овом пројекту. Захваљујући њиховим упутствима, конкретним референцама и правовременим смерницама успео сам да попуним кључне празнине у знању и да рад доведем до краја.

Захваљујем се и свим сарадницима лабораторије за роботiku на колегијалном радном окружењу и свакодневној размени идеја.

Михајло Стевановић
У Београду, јун 2026. године

Садржај

1 Увод

Савремена индустријска аутоматизација суочава се са растућом потребом за роботским системима способним да извршавају задатке прецизне монтаже (енгл. *assembly*) које је, до скоро, могуће обавити искључиво уз помоћ руке оператора. Кабловска инфраструктура - конектори, кабловске везице и сродни савитљиви елементи, незаобилазна је у производним линијама аутомобилске, ваздухопловне и медицинске индустрије. Упркос дугогодишњем напретку у роботској манипулацији, аутоматско уметање кабла у конекторски порт остаје нерешен проблем и директно ограничава степен аутоматизације у производним погонима.

Овај задатак представља парадигматски пример такозваног проблема деформабилних линеарних објеката (енгл. *deformable linear objects*, DLO). За разлику од крутих тела, кабл испољава комплексну механику деформације која се не може поуздано унапред предвидети: чак и при идентичним почетним условима, конфигурација кабла у простору варира на начин неподложен аналитичком моделовању. Истовремено, успешна инсерција захтева прецизност на нивоу неколико милиметара, свако одступање end-effector-а изнад те границе резултује неуспехом задатка. Ова комбинација непредвидивости деформације и захтеване прецизности чини аутоматско уметање кабла једним од отворених проблема индустријске роботике.

Овај рад настао је у оквиру учешћа на такмичењу Intrinsic AI for Industry Challenge, које организује компанија Intrinsic (Alphabet Inc.), а које је усмерено на задатке прецизне роботске манипулације у индустријском контексту. За потребе учесника, Intrinsic је обезбедио потпуно конфигурисано симулационо окружење: NVIDIA Isaac Sim toolkit за физичку симулацију засновану на GPU рендеровању и фотореалистичном ray tracing-у, OpenUSD склопове за дефиницију сцене, робота и задатка, те Docker контејнер са свим потребним библиотекама унапред инсталираним и међусобно усклађеним, из ког је могуће директно покретати симулације и тренирати политике. Овај стандардизован setup елиминисао је проблем конфигурације окружења и обезбедио потпуно репродукцибилне услове за систематско поређење метода.

Класични приступи решавању проблема DLO манипулације заснивају се на експлицитном моделовању геометрије и динамике кабла те планирању путање на основу тог модела. Ови приступи носе високу рачунарску цену и остају осетљиви на грешке услед немоделованог понашања. Као алтернатива, у овом раду истражују се методе учења имитацијама (енгл. *imitation learning*, IL) - парадигма у којој агент директно учи политику (пресликавање опсервација у акције) из демонстрација стручног агента, без потребе за експлицитним моделом динамике окружења. Конкретно, поређене су две савремене IL архитектуре: Action Chunking with Transformers (ACT) [8] и Diffusion Policy (DP) [7], обе у формулацији клонирања понашања (енгл. *behavioral cloning*, BC). Скуп демонстрација генерисан је путем такозване *oracle политике* — скриптованог агента заснованог на коначном аутомату (енгл. *state machine*) коме је, за разлику од тренираних политика, омогућен привилегован приступ апсолутним координатама циљног порта у симулационом окружењу. Тренирани модели ту информацију не поседују — они уче искључиво из опсервација (RGB слике камере, позиција end-effector-а) и акција које је oracle извршио, чиме је задатак учења реалистично отежан у складу са ограничењима стварних роботских система.

Централно истраживачко питање рада гласи: *колико далеко, и под којим условима, методе учења имитацијама могу да достигну задовољавајући ниво перформанси на задатку с милиметарском прецизношћу?* Из овог општег питања произлазе четири

конкретна истраживачка питања:

1. Колики број демонстрација је неопходан да модел достигне прихватљив проценат успешности (енгл. *success rate*)?
2. Која архитектура - АСТ или DP - боље скалира с величином скупа података за обуку?
3. Какав је утицај аугментације података и синтетичког шума на опсервације на робустност и способност генерализације?
4. Где се налази „плафон” перформанси ових метода на овом типу задатка и шта га детерминише?

Допринос овог рада је троструки. Прво, пружа се систематска експериментална студија граница двеју савремених ИЛ метода на задатку високе прецизности, у контролисаном симулационом окружењу са стандардизованом огасле политиком за генерисање демонстрација. Друго, анализира се зависност перформанси од величине скупа података и одређује оквирни минималан број демонстрација неопходан за прихватљив проценат успешности (енгл. *success rate*). Треће, квантификује се утицај аугментације и додатог шума на перформансе, пружајући смернице за практичну примену ИЛ метода у индустријским условима.

Рад је организован на следећи начин. Поглавље ?? даје преглед релевантне литературе из области учења имитацијама, са посебним освртом на АСТ и Diffusion Policy, као и сродне радове о роботској манипулацији деформабилним објектима. У Поглављу ?? описују се формулација проблема, архитектуре модела и поступак генерисања скупа демонстрација путем огасле политике. Поглавље ?? детаљно излаже симулационо окружење, простор опсервација и акција, хиперпараметре и метрике евалуације. Резултати свих експерименталних димензија приказани су у Поглављу ??, а њихова интерпретација и ограничења дискутовани у Поглављу ?. Поглавље ?? доноси закључна разматрања и правце будућих истраживања.

2 Преглед литературе

2.1 Учење имитацијама и клонирање понашања

Учење имитацијама (IL) је парадигма у оквиру које агент стиче политику π опонашањем стручног демонстратора, без директног дефинисања функције награде окружења. Најједноставнији облик IL-а је клонирање понашања (BC), уведено у контексту аутономне навигације у систему ALVINN [1]. У BC формулацији, политика се тренира надгледаним учењем на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$:

$$\pi^* = \arg \min_{\pi} \mathbb{E}_{(\mathbf{o}, \mathbf{a}) \sim \mathcal{D}} [\mathcal{L}(\pi(\mathbf{o}), \mathbf{a})], \quad (1)$$

где $\mathbf{o}$ означава опсервацију, $\mathbf{a}$ акцију стручног агента, а $\mathcal{L}$ критеријумску функцију губитка.

Кључно ограничење BC-а је проблем акумулације грешке: мала одступања у предвиђеним акцијама нагомиланим ефектом одводе агента у стања која нису покривена скупом демонстрација, а политика нема усвојеног понашања за реоријентацију и поправку из таквих стања. Овај феномен, познат као *distribution shift*, математички је формализовао Ross et al. [2], а у истом раду предложен је алгоритам DAgger (Dataset Aggregation) — итеративни поступак обогаћивања скупа демонстрација стањима насталим током евалуације (енгл. *rollout-a*) тренираног агента. Свеобухватна студија Mandlekar et al. [5] на Robomimic benchmark-у показала је да на успешност BC-а у роботској манипулацији пресудно утичу квалитет и покривеност простора стања у демонстрацијама, а не искључиво архитектура модела.

2.2 Action Chunking with Transformers (ACT)

ACT је метода учења имитацијама коју су предложили Zhao et al. [8] за задатке прецизне биманипулације. Централни допринос је концепт *action chunking*-а: уместо предвиђања јединичне акције у сваком временском кораку, политика предвиђа блок (chunk) од k узастопних акција $(\mathbf{a}_t, \mathbf{a}_{t+1}, \dots, \mathbf{a}_{t+k-1})$. Ефективни хоризонт задатка тако се смањује за фактор k , чиме се директно ублажава проблем акумулације грешке [2] — уместо T независних одлука политика доноси свега $\lceil T/k \rceil$.

Архитектура ACT-а комбинује условни варијациони аутоенкодер (CVAE) и кодер-декодер трансформер (Сл. ??):

- **CVAE кодер** (активан искључиво током тренинга): прима секвенцу акција из демонстрације и тренутне позиције зглобова, те их сажима у латентну променљиву $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$. Улога CVAE-а је моделовање вишемодалности у демонстрацијама — различити стилови извршавања истог задатка кодирају се у различите вредности $\mathbf{z}$. У фази примене, CVAE кодер се изоставља, а вредност латентног вектора $\mathbf{z}$ поставља на нулу.
- **Трансформерски декодер**: прима визуелне карактеристике N RGB камера (кодоване ResNet18 кичмом), позиције зглобова и $\mathbf{z}$, те унакрсним механизмом пажње генерише предвиђени блок акција. Дизајн декодера заснован је на DETR архитектури са учивим позиционим кодовима у улози упитних вектора.

Критеријумска функција током тренинга комбинује L1 реконструкцијску грешку и KL регуларизацију:

Место за слику: архитектура АСТ политике (CVAE кодер и
кодер-декодер трансформер)
(заменити фајлом images/act_arhitektura.pdf)

Слика 1: Архитектура АСТ политике. Прилагођено из [8].

$$\mathcal{L}_{\text{ACT}} = \mathbb{E}[\|\hat{\mathbf{a}} - \mathbf{a}\|_1] + \beta \cdot D_{\text{KL}}(\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2 \mathbf{I}) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})), \quad (2)$$

где је β хиперпараметар (подразумевано $\beta = 10$) који уравнива прецизност предвиђања и регуларизацију латентног простора.

За глаткост покрета при преклапајућим акцијским блоковима, АСТ опционо примењује временско усредњавање (енгл. *temporal ensembling*): предвиђања за исти тренутак из вишеструких узастопних читавања политике комбинују се са експоненцијалним тежинама $w_i = e^{-m \cdot i}$. На задацима прецизне биманипулације у физичком окружењу АСТ постиже успешност 80–96% [8], уз значајно надмашивање референтних метода BC-ConvMLP, BeT и VINN. Аблациона студија у истом раду показала је да само повећање величине блока са $k=1$ на $k=100$ побољшава успешност са 1% на 44% на репрезентативном задатку биманипулације.

2.3 Diffusion Policy


Diffusion Policy (DP) је метода учења политике коју су увели Chi et al. [7], заснована на одшумљавању дифузијским вероватносним моделима (DDPM) [4] примењеним на простор акција роботске политике. Кључна идеја је представљање условне расподеле акција $p(\mathbf{A}_t \mid \mathbf{O}_t)$ кроз итеративни поступак уклањања шума:

$$\mathbf{x}^{(k-1)} = \alpha(\mathbf{x}^{(k)} - \gamma \epsilon_{\theta}(\mathbf{x}^{(k)}, k, \mathbf{O}_t)) + \boldsymbol{\eta}, \quad \boldsymbol{\eta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}), \quad (3)$$

где $\mathbf{x}^{(K)}$ представља иницијални Гаусов шум, а ϵ_{θ} мрежу тренирану да предвиди шум условљен опсервацијом $\mathbf{O}_t$. Поступак поступно претвара насумичан шум у кохерентан акцијски план кроз K корака одшумљавања. Применом DDIM [6] шеме потребан број ових корака смањује се са 100 на свега 10, чиме се постиже кашњење испод 0,1 с при примени политике на GPU.

DP такође предвиђа секвенце акција (T_p корака), али извршава само $T_a < T_p$ пре следеће активације политике, остварујући баланс дугорочног планирања и брзе реакције на тренутне опсервације. Предложена су два архитектурална варијанта (Сл. ??):

- **Conv-DP**: 1D временске конволуције са Feature-wise Linear Modulation (FiLM) за условљавање опсервацијама; поуздан у широком спектру задатака.
- **Trans-DP**: transformer decoder блокови са каузалним маскирањем пажње; надмашује Conv-DP на задацима са нагло променљивим и вишемодалним акцијама.



Слика 2: Архитектура Diffusion Policy. Прилагођено из [7].

Евалуација на 15 задатака из четири скупа референтних задатака (укључујући Robomimic [5]) показала је просечно унапређење од 46,9% у односу на претходне BC методе [7]. Кључна предност DP-а у односу на детерминистичке регресионе политике је природна способност моделовања вишемодалних расподела акција: у ситуацијама са вишеструким оптималним путањама DP не пати од колапса мода (енгл. *mode collapse*).

2.4 Роботска манипулација деформабилних линеарних објеката

Деформабилни линеарни објекти (DLO) — жице, каблови и слични савитљиви елементи — представљају засебну и отворену класу проблема у роботској манипулацији [3]. За разлику од крутих тела, чији је положај у потпуности одређен шест степени слободе, стање DLO-а захтева опис бесконачно-димензионог конфигурационог простора деформације. Аналитичко моделовање ове динамике носи висок рачунарски захтев и оставља значајне немоделоване ефекте услед трења, вискоеластичности материјала и контакта са окружењем [3].

Традиционални приступи манипулацији DLO-а ослањали су се на сензоре силе и момента или на физичке моделе засноване на Косератовој (енгл. *Cosserat*) теорији еластичних штапова, постижући ограничену применљивост у условима непредвидивих деформација. Задатак инсерције кабла у конекторски порт додатно захтева прецизност на нивоу неколико милиметара — свако одступање end-effector-а изнад овог прага резултује механичким неуспехом. Ова комбинација непредвидивости деформације и захтеване прецизности чини инсерцију кабла репрезентативним примером задатка за који методе засноване на моделски-слободном учењу из демонстрација — какве су АСТ и DP — представљају природну алтернативу приступима заснованим на експлицитном моделу динамике.

3 Методологија

Методолошки оквир рада обухвата четири целине: скриптовану *oracle* политику за генерисање демонстрација, формирање скупа демонстрација у LeRobot формату, тренинг политика клонирањем понашања и евалуацију у симулационом окружењу. Кључна одлика поставе је асиметрија информација: *oracle* политика има приступ апсолутним координатама порта, док трениране политике одлучују искључиво на основу опсервација. Целокупан ток података приказан је на слици ??.

3.1 Формулација проблема

Задатак разматран у овом раду је аутономна инсерција кабла у конекторски порт у симулационом окружењу са шест-степенно-слободним UR роботом. Политика управља роботом на фреквенцији до 20 Hz и у сваком дискретном тренутку t прима опсервацију $\mathbf{o}_t$ и одређује акцију $\mathbf{a}_t$.

Простор опсервација. Опсервација у тренутку t састоји се од визуелне и проприо-цептивне компоненте:

$$\mathbf{o}_t = (\mathbf{I}_t^c, \mathbf{I}_t^l, \mathbf{I}_t^r, \mathbf{s}_t), \quad (4)$$

где $\mathbf{I}_t^c, \mathbf{I}_t^l, \mathbf{I}_t^r \in \mathbb{R}^{H \times W \times 3}$ означавају RGB слике централне, леве и десне камере, а $\mathbf{s}_t \in \mathbb{R}^{56}$ проприоцептивни вектор стања добијен конкатенацијом следећих величина (све изражене у базном координатном систему робота):


- $\mathbf{q}_t, \dot{\mathbf{q}}_t, \boldsymbol{\tau}_t \in \mathbb{R}^6$ — позиције, брзине и моменти шест зглобова роботске руке,
- $\mathbf{p}_t^{\text{tcp}} \in \mathbb{R}^3, \mathbf{r}_t^{\text{tcp}} \in \mathbb{R}^4$ — позиција и оријентација (кватернион) радне тачке алата (TCP),
- $\mathbf{p}_t^{\text{eef}} \in \mathbb{R}^3, \mathbf{r}_t^{\text{eef}} \in \mathbb{R}^4$ — позиција и оријентација референтног оквира хватача,
- $\mathbf{v}_t^{\text{tcp}}, \boldsymbol{\omega}_t^{\text{tcp}}, \mathbf{v}_t^{\text{eef}}, \boldsymbol{\omega}_t^{\text{eef}} \in \mathbb{R}^3$ — линеарне и угаоне брзине TCP-а и хватача,
- $\mathbf{w}_t \in \mathbb{R}^6$ — сила и момент на завршном зглобу хватача (wrist wrench),
- $\mathbf{a}_{t-1} \in \mathbb{R}^6$ — акција примењена у претходном временском кораку.

Кључно ограничење реалистичности задатка: политика не прима апсолутне координате циљног порта. Та информација је доступна искључиво *oracle* политици коришћеној за генерисање скупа демонстрација $\mathcal{D}$.

Простор акција. Акција политике у сваком временском кораку је прираст позе TCP-а у картезијанском простору, изражен као шестодимензиони вектор:

$$\mathbf{a}_t = (\Delta \mathbf{p}_t, \Delta \boldsymbol{\theta}_t) \in \mathbb{R}^6, \quad (5)$$

где $\Delta \mathbf{p}_t \in \mathbb{R}^3$ означава транслаторни прираст, а $\Delta \boldsymbol{\theta}_t \in \mathbb{R}^3$ ротациони прираст у форми вектора ротације (оса--угао). Овај прираст се прослеђује управљачу заснованом на диференцијалној инверзној кинематици (DiffIK), који га преводи у циљне позиције зглобова робота. Хватач је током целог задатка у затвореном положају, па акција не обухвата управљачку променљиву прстију хватача.



Слика 3: Ток података кроз систем: oracle политика са приступом координатам порта генерише демонстрације преко машине стања и DiffIK управљача, успешне епизоде се чувају у LeRobot скуп демонстрација, на коме се тренирају ACT и Diffusion Policy политике, а потом евалуирају без привилеговане информације.

Формулација клонирања понашања. Задатак учења формулише се у оквиру клонирања понашања (??): политика π_θ тренира се на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$ генерисаних огасле политиком, надгледаном минимизацијом грешке предвиђене акције. Оба архитектурална варијанта разматрана у овом раду — АСТ и Diffusion Policy — тренирана су у идентичном ВС оквиру на заједничком скупу демонстрација, чиме је обезбеђена поредивост резултата.

Метрике евалуације. Успешност политике мери се двама метрикама. Примарна је бинарна стопа успешности:

$$\text{SR} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\text{кабл потпуно уметнут у епизоди } i], \quad (6)$$

где N означава укупан број евалуационих епизода. Секундарна метрика је минимална еуклидска удаљеност TCP-а од циљне позиције инсерције током епизоде:

$$d_{\min} = \min_{t \in [1, T]} \|\mathbf{p}_t - \mathbf{p}^*\|_2, \quad (7)$$

где $\mathbf{p}^* \in \mathbb{R}^3$ означава циљну позицију порта. Метрика $d_{\min}$ омогућава квантификацију прецизности грешке и у неуспелим епизодама, пружајући финиј увид у ниво перформанси изван бинарног критеријума (??).

3.2 Имплементација АСТ политике

Архитектура АСТ-а, описана у одељку ??, у овом раду инстанцирана је коришћењем имплементације из библиотеке LeRobot. Политика прима опсервацију $\mathbf{o}_t$ из (??) и предвиђа блок од k узастопних акција у простору (??), што је приказано на слици ??.

Визуелни део опсервације — слике три камере — кодира се ResNet-18 кичмом, чији излаз чини скуп просторних токена за трансформерски декодер. Проприоцептивни вектор $\mathbf{s}_t$ пројектује се линеарним слојем у засебан улазни токен. CVAE кодер активан је искључиво током тренинга и моделује вишемодалност демонстрација кроз латентну променљиву $\mathbf{z}$, док се у фази примене поставља $\mathbf{z} = \mathbf{0}$. Тренинг се води минимизацијом комбиноване функције губитка (??).

Ради повећања робусности на варијације осветљења и положаја камере, на улазне слике се током тренинга примењују фотометријске и геометријске аугментације. У фази примене политика користи временско усредњавање (temporal ensembling), чиме се преклапајућа предвиђања акцијских блокова комбинују у глатку управљачку секвенцу. Конкретне вредности хиперпараметара (величина блока k , тежина β , стопа учења и параметри аугментације) наведене су у одељку ??.

3.3 Имплементација Diffusion Policy

Diffusion Policy инстанцирана је такође у оквиру библиотеке LeRobot, на истом скупу демонстрација $\mathcal{D}$ и са идентичним простором опсервација (??) и акција (??) као АСТ (Сл. ??), чиме је обезбеђена поредивост двеју метода.

Коришћена је конволуциона варијанта (Conv-DP): мрежа за одшумљавање заснована је на једнодимензионом U-Net-у, а условљавање опсервацијом остварено је FiLM модулацијом. Сlike три камере кодирају се ResNet кичмом, а добијени визуелни дескриптори се заједно са проприоцептивним вектором $\mathbf{s}_t$ сажимају у условни вектор

Место за слику: улазно-излазна шема АСТ политике у овом раду
 $3 \times \text{RGB}(\mathbf{I}^c, \mathbf{I}^l, \mathbf{I}^r) + \text{стање } \mathbf{s}_t \in \mathbb{R}^{56} \rightarrow \text{блок од } k \text{ акција } \mathbf{a}_t \in \mathbb{R}^6$
 (заменити фајлом images/act_ulaz_izlaz.pdf)

Слика 4: Улазно-излазна шема АСТ политике примењене у овом раду.

опсервације $\mathbf{O}_t$. Мрежа ϵ_θ тренира се да предвиди шум додат на акцијску секвенцу, у складу са (??), минимизацијом средње квадратне грешке предвиђеног шума.

У фази примене, акцијска секвенца се генерише итеративним одшумљавањем из Гаусовог шума, условљеним текућом опсервацијом, при чему се користи DDIM шема ради смањења броја корака одшумљавања. Политика предвиђа секвенцу од T_p корака, а извршава њених првих $T_a < T_p$ пре поновне активације (рецидирајући хоризонт). Вредности хиперпараметара (хоризонти T_p и T_a , број корака одшумљавања, стопа учења) дате су у одељку ??.

Место за слику: улазно-излазна шема Diffusion Policy у овом раду
 условљавање опсервацијом $\mathbf{O}_t \rightarrow$ итеративно одшумљавање $\rightarrow$ секвенца од T_p
 акција
 (заменити фајлом images/dp_ulaz_izlaz.pdf)

Слика 5: Улазно-излазна шема Diffusion Policy примењене у овом раду.

4 Експериментална постава

5 Резултати

6 Дискусија

7 Закључак

Списак слика

Списак табела

Литература

- [1] Dean A. Pomerleau. „ALVINN: An Autonomous Land Vehicle In a Neural Network”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 2. 1989., стр. 305–313.
- [2] Stéphane Ross, Geoffrey J. Gordon и J. Andrew Bagnell. „A Reduction of Imitation Learning and Structured Prediction to No-Regret Online Learning”. У: *Proceedings of the International Conference on Artificial Intelligence and Statistics (AISTATS)*. Сб. 15. 2011., стр. 627–635.
- [3] Juan Sanchez и др. „Robotic manipulation and sensing of deformable objects in domestic and industrial settings: a survey”. У: *The International Journal of Robotics Research* 37.7 (2018.), стр. 688–716. doi: 10.1177/0278364918779698.
- [4] Jonathan Ho, Ajay Jain и Pieter Abbeel. „Denoising Diffusion Probabilistic Models”. У: *Advances in Neural Information Processing Systems (NeurIPS)*. Сб. 33. 2020., стр. 6840–6851.
- [5] Ajay Mandlekar и др. „What Matters in Learning from Offline Human Demonstrations for Robot Manipulation”. У: *Proceedings of the Conference on Robot Learning (CoRL)*. 2021.
- [6] Jiaming Song, Chenlin Meng и Stefano Ermon. „Denoising Diffusion Implicit Models”. У: *International Conference on Learning Representations (ICLR)*. 2021.
- [7] Cheng Chi и др. „Diffusion Policy: Visuomotor Policy Learning via Action Diffusion”. У: *Proceedings of Robotics: Science and Systems (RSS)*. 2023. doi: 10.15607/RSS.2023.XIX.026.
- [8] Tony Z. Zhao и др. „Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware”. У: *Proceedings of Robotics: Science and Systems (RSS)*. 2023. doi: 10.15607/RSS.2023.XIX.016.