



ЕЛЕКТРОТЕХНИЧКИ ФАКУЛТЕТ
УНИВЕРЗИТЕТ У БЕОГРАДУ

ДИПЛОМСКИ РАД

**Испитивање границе учења
имитацијама у симулационом
окружењу за роботско извршавање
високо прецизних задатака**

Михајло Стевановић
Број индекса: 2022/0315

Ментор
Проф. др Коста Јовановић

18. јун 2026.

Захвалница

Желим да изразим искрену захвалност проф. др Кости Јовановићу на указаном поверењу и прилици да своју студентску праксу, а потом и дипломски рад, реализујем у лабораторији Електротехничког факултета у Палати Науке. Рад у том окружењу пружио ми је непроцењиво практично искуство и непосредан увид у процес научноистраживачког рада.

Посебну захвалност дугујем својим менторима, Давиду Сеничићу и др Филипу Бечановићу, на издвојеном времену, стрпљењу и знању које су несебично делили са мном током рада на овом пројекту. Захваљујући њиховим упутствима, конкретним референцама и правовременим смерницама успео сам да попуним кључне празнине у знању и да рад доведем до краја.

Захваљујем се и свим сарадницима лабораторије за роботiku на колегијалном радном окружењу и свакодневној размени идеја.

Михајло Стевановић
У Београду, јун 2026. године

Садржај

Захвалница	i
1 Увод	1
2 Преглед литературе	3
2.1 Учење имитацијама и клонирање понашања	3
2.2 Action Chunking with Transformers (ACT)	3
2.3 Diffusion Policy	4
2.4 Роботска манипулација деформабилних линеарних објеката	4
3 Методологија	6
3.1 Формулација проблема	6
4 Експериментална постава	8
5 Резултати	8
6 Дискусија	8
7 Закључак	8
Списак слика	8
Списак табела	8

1 Увод

Савремена индустријска аутоматизација суочава се са растућом потребом за роботским системима способним да извршавају задатке прецизне монтаже (енгл. *assembly*) које је, до скоро, могуће обавити искључиво уз помоћ руке оператора. Кабловска инфраструктура - конектори, кабловске везице и сродни савитљиви елементи, незаобилазна је у производним линијама аутомобилске, ваздухопловне и медицинске индустрије. Упркос дугогодишњем напретку у роботској манипулацији, аутоматско уметање кабла у конекторски порт остаје нерешен проблем и директно ограничава степен аутоматизације у производним погонима.

Овај задатак представља парадигматски пример такозваног проблема деформабилних линеарних објеката (енгл. *deformable linear objects*, DLO). За разлику од крутих тела, кабл испољава комплексну механику деформације која се не може поуздано унапред предвидети: чак и при идентичним почетним условима, конфигурација кабла у простору варира на начин неподложен аналитичком моделовању. Истовремено, успешна инсерција захтева прецизност на нивоу неколико милиметара, свако одступање end-effector-а изнад те границе резултује неуспехом задатка. Ова комбинација непредвидивости деформације и захтеване прецизности чини аутоматско уметање кабла једним од отворених проблема индустријске роботике.

Овај рад настао је у оквиру учешћа на такмичењу Intrinsic AI for Industry Challenge, које организује компанија Intrinsic (Alphabet Inc.), а које је усмерено на задатке прецизне роботске манипулације у индустријском контексту. За потребе учесника, Intrinsic је обезбедио потпуно конфигурисано симулационо окружење: NVIDIA Isaac Sim toolkit за физичку симулацију засновану на GPU рендеровању и фотореалистичном ray tracing-у, OpenUSD склопове за дефиницију сцене, робота и задатка, те Docker контејнер са свим потребним библиотекама унапред инсталираним и међусобно усклађеним, из ког је могуће директно покретати симулације и тренирати политике. Овај стандардизован setup елиминисао је проблем конфигурације окружења и обезбедио потпуно репродуцибилне услове за систематско поређење метода.

Класични приступи решавању проблема DLO манипулације заснивају се на експлицитном моделовању геометрије и динамике кабла те планирању путање на основу тог модела. Ови приступи носе високу рачунарску цену и остају осетљиви на грешке услед немоделованог понашања. Као алтернатива, у овом раду истражују се методе учења имитацијама (енгл. *imitation learning*, IL) - парадигма у којој агент директно учи политику (пресликавање опсервација у акције) из демонстрација стручног агента, без потребе за експлицитним моделом динамике окружења. Конкретно, поређене су две савремене IL архитектуре: Action Chunking with Transformers (ACT) [zhao2023act] и Diffusion Policy (DP) [chi2023diffusionpolicy], обе у формулацији клонирања понашања (енгл. *behavioral cloning*, BC). Скуп демонстрација генерисан је путем такозване *oracle политике* — скриптованог агента заснованог на коначном аутомату (енгл. *state machine*) коме је, за разлику од тренираних политика, омогућен привилегован приступ апсолутним координатама циљног порта у симулационом окружењу. Тренирани модели ту информацију не поседују — они уче искључиво из опсервација (RGB слике камере, позиција end-effector-а) и акција које је oracle извршио, чиме је задатак учења реалистично отежан у складу са ограничењима стварних роботских система.

Централно истраживачко питање рада гласи: *колико далеко, и под којим условима, методе учења имитацијама могу да достигну задовољавајући ниво перформанси на задатку с милиметарском прецизношћу?* Из овог општег питања произлазе четири

конкретна истраживачка питања:

1. Колики број демонстрација је неопходан да модел достигне прихватљив проценат успешности (енгл. *success rate*)?
2. Која архитектура - АСТ или DP - боље скалира с величином скупа података за обуку?
3. Какав је утицај аугментације података и синтетичког шума на опсервације на робустност и способност генерализације?
4. Где се налази „плафон” перформанси ових метода на овом типу задатка и шта га детерминише?

Допринос овог рада је троструки. Прво, пружа се систематска експериментална студија граница двеју савремених ИЛ метода на задатку високе прецизности, у контролисаном симулационом окружењу са стандардизованом огасле политиком за генерисање демонстрација. Друго, анализира се зависност перформанси од величине скупа података и одређује оквирни минималан број демонстрација неопходан за прихватљив проценат успешности (енгл. *success rate*). Треће, квантификује се утицај аугментације и додатог шума на перформансе, пружајући смернице за практичну примену ИЛ метода у индустријским условима.

Рад је организован на следећи начин. Поглавље 2 даје преглед релевантне литературе из области учења имитацијама, са посебним освртом на АСТ и Diffusion Policy, као и сродне радове о роботској манипулацији деформабилним објектима. У Поглављу 3 описују се формулација проблема, архитектуре модела и поступак генерисања скупа демонстрација путем огасле политике. Поглавље 4 детаљно излаже симулационо окружење, простор опсервација и акција, хиперпараметре и метрике евалуације. Резултати свих експерименталних димензија приказани су у Поглављу 5, а њихова интерпретација и ограничења дискутовани у Поглављу 6. Поглавље 7 доноси закључна разматрања и правце будућих истраживања.

2 Преглед литературе

2.1 Учење имитацијама и клонирање понашања

Учење имитацијама (IL) је парадигма у оквиру које агент стиче политику π опонашањем стручног демонстратора, без директног дефинисања функције награде окружења. Најједноставнији облик IL-а је клонирање понашања (BC), уведено у контексту аутономне навигације у систему ALVINN [pomerleau1989alvinn]. У BC формулацији, политика се тренира надгледаним учењем на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$:

$$\pi^* = \arg \min_{\pi} \mathbb{E}_{(\mathbf{o}, \mathbf{a}) \sim \mathcal{D}} [\mathcal{L}(\pi(\mathbf{o}), \mathbf{a})], \quad (1)$$

где $\mathbf{o}$ означава опсервацију, $\mathbf{a}$ акцију стручног агента, а $\mathcal{L}$ критеријумску функцију губитка.

Кључно ограничење BC-а је проблем акумулације грешке: мала одступања у предвиђеним акцијама нагомиланим ефектом одводе агента у стања која нису покривена скупом демонстрација, а политика нема усвојеног понашања за реоријентацију и поправку из таквих стања. Овај феномен, познат као *distribution shift*, математички је формализовао Ross et al. [ross2011dagger], а у истом раду предложен је алгоритам DAgger (Dataset Aggregation) — итеративни поступак обогаћивања скупа демонстрација стањима насталим током евалуације (енгл. *rollout-a*) тренираног агента. Свеобухватна студија Mandlekar et al. [mandlekar2021robomimic] на Robomimic benchmark-у показала је да на успешност BC-а у роботској манипулацији пресудно утичу квалитет и покривеност простора стања у демонстрацијама, а не искључиво архитектура модела.

2.2 Action Chunking with Transformers (ACT)

ACT је метода учења имитацијама коју су предложили Zhao et al. [zhao2023act] за задатке прецизне биманипулације. Централни допринос је концепт *action chunking*-а: уместо предвиђања јединичне акције у сваком временском кораку, политика предвиђа блок (chunk) од k узастопних акција $(\mathbf{a}_t, \mathbf{a}_{t+1}, \dots, \mathbf{a}_{t+k-1})$. Ефективни хоризонт задатка тако се смањује за фактор k , чиме се директно ублажава проблем акумулације грешке [ross2011dagger] — уместо T независних одлука политика доноси свега $\lceil T/k \rceil$.

Архитектура ACT-а комбинује условни варијациони аутоенкодер (CVAE) и кодер-декодер трансформер:

- **CVAE кодер** (активан искључиво током тренинга): прима секвенцу акција из демонстрације и тренутне позиције зглобова, те их сажима у латентну променљиву $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$. Улога CVAE-а је моделовање вишемодалности у демонстрацијама — различити стилови извршавања истог задатка кодирају се у различите вредности $\mathbf{z}$. У фази примене, CVAE кодер се изоставља, а вредност латентног вектора $\mathbf{z}$ поставља на нулу.
- **Трансформерски декодер**: прима визуелне карактеристике N RGB камера (кодоване ResNet18 кичмом), позиције зглобова и $\mathbf{z}$, те унакрсним механизмом пажње генерише предвиђени блок акција. Дизајн декодера заснован је на DETR архитектури са учивим позиционим кодовима у улози упитних вектора.

Критеријумска функција током тренинга комбинује L1 реконструкцијску грешку и KL регуларизацију:

$$\mathcal{L}_{\text{ACT}} = \mathbb{E}[\|\hat{\mathbf{a}} - \mathbf{a}\|_1] + \beta \cdot D_{\text{KL}}(\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma}^2 \mathbf{I}) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})), \quad (2)$$

где је β хиперпараметар (подразумевано $\beta = 10$) који уравнотежује прецизност предвиђања и регуларизацију латентног простора.

За глаткост покрета при преклапајућим акцијским блоковима, АСТ опционо примењује временско усредњавање (енгл. *temporal ensembling*): предвиђања за исти тренутак из вишеструких узастопних читавања политике комбинују се са експоненцијалним тежинама $w_i = e^{-m \cdot i}$. На задацима прецизне биманипулације у физичком окружењу АСТ постиже успешност 80–96% [zhao2023act], уз значајно надмашивање референтних метода BC-ConvMLP, BeT и VINN. Аблациона студија у истом раду показала је да само повећање величине блока са $k=1$ на $k=100$ побољшава успешност са 1% на 44% на репрезентативном задатку биманипулације.

2.3 Diffusion Policy

Diffusion Policy (DP) је метода учења политике коју су увели Chi et al. [chi2023diffusionpolicy], заснована на одшумљавању дифузијским вероватносним моделима (DDPM) [ho2020ddpm] примењеним на простор акција роботске политике. Кључна идеја је представљање условне расподеле акција $p(\mathbf{A}_t \mid \mathbf{O}_t)$ кроз итеративни поступак уклањања шума:

$$\mathbf{x}^{(k-1)} = \alpha(\mathbf{x}^{(k)} - \gamma \epsilon_{\theta}(\mathbf{x}^{(k)}, k, \mathbf{O}_t)) + \boldsymbol{\eta}, \quad \boldsymbol{\eta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}), \quad (3)$$

где $\mathbf{x}^{(K)}$ представља иницијални Гаусов шум, а ϵ_{θ} мрежу тренирану да предвиди шум условљен опсервацијом $\mathbf{O}_t$. Поступак поступно претвара насумичан шум у кохерентан акцијски план кроз K корака одшумљавања. Применом DDIM [song2021ddim] шеме потребан број ових корака смањује се са 100 на свега 10, чиме се постиже кашњење испод 0,1 с при примени политике на GPU.

DP такође предвиђа секвенце акција (T_p корака), али извршава само $T_a < T_p$ пре следеће активације политике, остварујући баланс дугорочног планирања и брзе реакције на тренутне опсервације. Предложена су два архитектурална варијанта:

- **Conv-DP**: 1D временске конволуције са Feature-wise Linear Modulation (FiLM) за условљавање опсервацијама; поуздан у широком спектру задатака.
- **Trans-DP**: transformer decoder блокови са каузалним маскирањем пажње; надмашује Conv-DP на задацима са нагло променљивим и вишемодалним акцијама.

Евалуација на 15 задатака из четири скупа референтних задатака (укључујући Robomimic [mandlekar2021robomimic]) показала је просечно унапређење од 46,9% у односу на претходне BC методе [chi2023diffusionpolicy]. Кључна предност DP-а у односу на детерминистичке регресионе политике је природна способност моделовања вишемодалних расподела акција: у ситуацијама са вишеструким оптималним путањама DP не пати од колапса мода (енгл. *mode collapse*).

2.4 Роботска манипулација деформабилних линеарних објеката

Деформабилни линеарни објекти (DLO) — жице, каблови и слични савитљиви елементи — представљају засебну и отворену класу проблема у роботској манипулацији [sanchez2018dlo]. За разлику од крутих тела, чији је положај у потпуности одређен

шест степени слобode, стање DLO-а захтева опис бесконачно-димензионог конфигурационог простора деформације. Аналитичко моделовање ове динамике носи висок рачунарски захтев и оставља значајне немоделоване ефекте услед трења, вискоеластичности материјала и контакта са окружењем [sanchez2018dlo].

Традиционални приступи манипулацији DLO-а ослањали су се на сензоре силе и момента или на физичке моделе засноване на Косератовој (енгл. *Cosserat*) теорији еластичних штапова, постижући ограничену применљивост у условима непредвидивих деформација. Задатак инсерције кабла у конекторски порт додатно захтева прецизност на нивоу неколико милиметара — свако одступање end-effector-а изнад овог прага резултује механичким неуспехом. Ова комбинација непредвидивости деформације и захтеване прецизности чини инсерцију кабла репрезентативним примером задатка за који методе засноване на моделски-слободном учењу из демонстрација — какве су АСТ и DP — представљају природну алтернативу приступима заснованим на експлицитном моделу динамике.

3 Методологија

3.1 Формулација проблема

Задатак разматран у овом раду је аутономна инсерција кабла у конекторски порт у симулационом окружењу са шест-степенно-слободним UR роботом. Политика управља роботом на фреквенцији до 20 Hz и у сваком дискретном тренутку t прима опсервацију $\mathbf{o}_t$ и одређује акцију $\mathbf{a}_t$.

Простор опсервација. Опсервација у тренутку t дефинисана је као:

$$\mathbf{o}_t = (\mathbf{I}_t^{(1)}, \mathbf{I}_t^{(2)}, \mathbf{I}_t^{(3)}, \mathbf{q}_t, \mathbf{p}_t, \mathbf{w}_t), \quad (4)$$

где:

- $\mathbf{I}_t^{(i)} \in \mathbb{R}^{H \times W \times 3}, i \in \{1, 2, 3\}$ — RGB слике три камере монтиране на зглобу робота,
- $\mathbf{q}_t \in \mathbb{R}^6$ — угаоне позиције шест зглобова роботске руке (хватач је током целог задатка у затвореном положају),
- $\mathbf{p}_t \in SE(3)$ — тренутна поза TCP-а (позиција и оријентација хватача),
- $\mathbf{w}_t \in \mathbb{R}^6$ — вектор оптерећења на зглобу (3D сила и 3D момент).

Кључно ограничење реалистичности задатка: политика не прима апсолутне координате циљног порта. Та информација је доступна искључиво огасле политици коришћењем за генерисање скупа демонстрација $\mathcal{D}$.

Простор акција. Акција политике у сваком временском кораку је прираст позиције TCP-а у картезијанском простору:

$$\mathbf{a}_t = \Delta \mathbf{p}_t \in \mathbb{R}^3. \quad (5)$$

Формулација клонирања понашања. Задатак учења формулише се у оквиру клонирања понашања (1): политика π_θ тренира се на скупу демонстрација $\mathcal{D} = \{(\mathbf{o}_t, \mathbf{a}_t)\}_{t=1}^T$ генерисаних огасле политиком, надгледаном минимизацијом грешке предвиђене акције. Оба архитектурална варијанта разматрана у овом раду — ACT и Diffusion Policy — тренирана су у идентичном BC оквиру на заједничком скупу демонстрација, чиме је обезбеђена поредивост резултата.

Метрике евалуације. Успешност политике мери се двама метрикама. Примарна је бинарна стопа успешности:

$$SR = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[\text{кабл потпуно уметнут у епизоди } i], \quad (6)$$

где N означава укупан број евалуационих епизода. Секундарна метрика је минимална еуклидска удаљеност TCP-а од циљне позиције инсерције током епизоде:

$$d_{\min} = \min_{t \in [1, T]} \|\mathbf{p}_t - \mathbf{p}^*\|_2, \quad (7)$$

где $\mathbf{p}^* \in \mathbb{R}^3$ означава циљну позицију порта. Метрика $d_{\min}$ омогућава квантификацију прецизности грешке и у неуспелим епизодама, пружајући финиј увид у ниво перформанси изван бинарног критеријума (6).

4 Експериментална постава

5 Резултати

6 Дискусија

7 Закључак

Списак слика

Списак табела